

Développement d'un système d'interface cerveau-ordinateur
basé sur l'EEG pour le contrôle de la marche en réalité virtuelle
dans un contexte de réadaptation motrice.

Par

Emma CARILLO

**MAÎTRISE EN GÉNIE DES TECHNOLOGIES DE L'INFORMATION
M. ING.**

MONTRÉAL, LE 6 AOUT 2026

ÉCOLE DE TECHNOLOGIE SUPÉRIEURE
UNIVERSITÉ DU QUÉBEC

© Tous droits réservés

Cette licence signifie qu'il est interdit de reproduire, d'enregistrer ou de diffuser en tout ou en partie, le présent document. Le lecteur qui désire imprimer ou conserver sur un autre media une partie importante de ce document, doit obligatoirement en demander l'autorisation à l'auteur.

PRÉSENTATION DU JURY

CE RAPPORT DE PROJET A ÉTÉ ÉVALUÉ

PAR UN JURY COMPOSÉ DE :

David Labé, direction de projet
Département de génie logiciel et des TI à l'École de technologie supérieure

Cyril Duclos, codirection de projet
Université de Montréal

Roberto Erick Lopez Herrejon, présidence du jury
Département de génie logiciel et des TI à l'École de technologie supérieure

REMERCIEMENTS

Je tiens tout d'abord à remercier mon directeur de projet, le professeur David Labbé, pour son encadrement, sa disponibilité et ses précieux conseils tout au long de la réalisation de ce projet. Son expertise et ses orientations ont grandement contribué au développement de ce travail.

Je souhaite remercier les membres de l'équipe du laboratoire ainsi que du LIO au CRCHUM pour leur soutien, leurs échanges scientifiques et l'environnement de recherche stimulant qui ont favorisé l'avancement de ce projet.

Je tiens également à exprimer ma reconnaissance envers tous les participants dont les données ont été utilisées dans le cadre de cette étude. Leur contribution est essentielle à l'avancement de la recherche et à une meilleure compréhension des mécanismes liés à l'analyse des signaux EEG dans un contexte de réadaptation motrice.

Finalement, je remercie chaleureusement ma famille et mes proches pour leur soutien, leur encouragement et leur patience tout au long de mes études.

Développement d'un système d'interface cerveau-ordinateur basé sur l'EEG pour le contrôle de la marche en réalité virtuelle dans un contexte de réadaptation motrice.

Emma CARILLO

RÉSUMÉ

Les interfaces cerveau -ordinateur offrent de nouvelles perspectives pour soutenir la réadaptation motrice chez les personnes ayant subi un accident vasculaire cérébral ou présentant des atteintes neurologiques. En analysant l'activité cérébrale, ces systèmes permettent de détecter les intentions de mouvement et de les traduire en commandes pour des environnements interactifs, notamment en réalité virtuelle.

Ce projet vise à développer un système BCI basé sur l'analyse de signaux électroencéphalographiques (EEG) permettant le contrôle de la marche d'un avatar en réalité virtuelle. Les travaux portent sur l'analyse de données EEG recueillies lors de tâches d'imageries motrice liée à la marche ainsi que sur le développement de modèles de classification capables de reconnaître les intentions de mouvement.

Dans ce contexte, des approches d'apprentissage profond, notamment des architectures de réseau de neurones convolutionnels telles que EEGnet et DeepConvNet, sont étudiées afin d'améliorer la reconnaissance des intentions motrices à partir de signaux EEG. Les performances de ces modèles sont comparées à celles de méthodes de classification plus classiques, telles que LDA et RDLA.

Les résultats de cette étude permettent d'évaluer le potentiel des approches basées sur le deep learning pour améliorer la fiabilité et la précision des systèmes BCI destinés à la réadaptation motrice. A plus long terme, ce type de technologie pourrait contribuer au développement d'outils de rééducation plus immersifs, personnalisés et motivants pour les patients.

Mots-clés : interface cerveau-ordinateur, EEG, apprentissage profond, EEGNet, réalité virtuelle, réadaptation motrice.

Development of an EEG-based brain-computer interface system for controlling avatar walking in virtual reality for motor rehabilitation.

Emma CARILLO

ABSTRACT

Brain computer interface offer new opportunities to support motor rehabilitation in individuals who have experienced a stroke or other neurological impairments. By analyzing brain activity, these systems make it possible to detect movement intentions and translate them into commands for interactive environments, particularly in virtual reality.

This project aims to develop a BCI system based on the analysis of electroencephalographic (EEG) signals to control the walking of a virtual avatar in a virtual reality environment. The work focuses on the analysis of EEG data collected during motor imagery tasks related to walking, as well as on the development of classification models capable of recognizing movement intentions.

In this context, deep learning approaches, particularly convolutional neural network architectures such as EEGnet and DeepConvNet, are investigated to improve the recognition of motor intentions from EEG signals. The performance of these models is compared with that of more traditional classification methods, such as LDA and RLDA.

The results of this study make it possible to evaluate the potential of deep learning approaches to improve the reliability and accuracy of BCI systems intended for motor rehabilitation. In the longer term, this type of technology could contribute to the development of more immersive, personalized and motivating rehabilitation tools for patients.

Keywords: brain-computer interface, EEG, deep learning, EEGNet, virtual reality, motor rehabilitation.

TABLE DES MATIÈRES

REMERCIEMENTS.....	2
INTRODUCTION	14
0.1 CONTEXTE DE LA RECHERCHE.....	15
0.2 PROBLÉMATIQUE.....	16
0.3 OBJECTIF DU PROJET	16
0.4 ORGANISATION DU MÉMOIRE.....	17
0.5 DÉCLARATION SUR L'UTILISATION DE L'INTELLIGENCE ARTIFICIELLE :	17
CHAPITRE 1 NOTIONS FONDAMENTALES	19
1.1 INTERFACE CERVEAU – ORDINATEUR :	19
1.1.1 Principe des BCI :	19
1.1.2 Types de BCI :	20
1.2 SIGNAUX ÉLECTROENCÉPHALOGRAPHIQUES (EEG) :	23
1.2.1 Acquisition des signaux EEG :	23
1.2.2 Bandes de fréquence EEG :	24
1.2.3 Prétraitement des signaux EEG :	26
1.2.4 Électrodes sèches vs électrodes humides :	26
1.3 IMAGERIE MOTRICE :	28
1.4 MÉTHODES DE CLASSIFICATION DES SIGNAUX EEG :	30
1.4.1 Méthodes de classification classiques :	30
1.4.2 Approches basées sur l'apprentissage profond :	31
1.4.3 Architecture EEGNet :	32
1.4.4 Architecture DeepConvNet :	33
CHAPITRE 2 REVUE DE LITTÉRATURE.....	34
2.1 BCI POUR LA READAPTATION MOTRICE :	34
2.1.1 Applications cliniques des BCI en réadaptation motrice :	34
2.1.2 Réalité virtuelle dans les BCI :	36
2.2 DECODAGE DES INTENTIONS MOTRICES DE LA MARCHÉ :	37
2.3 PERFORMANCES DES METHODES DE CLASSIFICATION :	38
2.2.1 Méthodes de classification classiques :	38
2.2.2 Architectures d'apprentissage profond :	38
2.3 SYNTHÈSE ET POSITIONNEMENT DU PROJET :	39
CHAPITRE 3 MATÉRIEL ET ACQUISITION DES DONNÉES :	41
3.1 PROTOCOLE EXPÉRIMENTAL :	41
3.1.1 Participants et conditions d'acquisition :	41
3.1.2 Tâches d'imagerie motrices réalisées :	42
3.1.3 Environnement de réalité virtuelle	43
3.2 SYSTÈME À ÉLECTRODES HUMIDES :	44
3.2.1 Description du matériel :	44
3.2.2 Caractéristiques du signal de référence :	45
3.3 SYSTÈME À ÉLECTRODES SÈCHES :	46
3.3.1 Description du matériel :	46
3.3.2 Procédure d'installation et vérification du signal :	48
3.3.3 Analyse spectrale et identification des bandes EEG pertinentes :	49

CHAPITRE 4 MÉTHODOLOGIE	51
4.1 PIPELINE DE PRÉTRAITEMENT DES SIGNAUX EEG :	51
4.1.1 Filtrage des signaux :	52
4.1.2 Segmentation et épochage :	53
4.1.3 Rejet des artefacts :	56
4.1.4 Normalisation :	56
4.2 MÉTHODES DE CLASSIFICATION :	57
4.2.1 RLDA — Analyse discriminante linéaire régularisée :	58
4.2.2 EEGNet — Architecture et paramétrage :	60
4.2.3 DeepConvNet — Architecture et paramétrage :	61
4.3 PROCÉDURE D'ENTRAÎNEMENT ET VALIDATION :	62
4.3.1 Stratégie de validation croisée :	62
4.3.2 Métriques d'évaluation :	64
CHAPITRE 5 RÉSULTATS	65
5.1 RÉSULTATS SUR LES DONNÉES À ÉLECTRODES HUMIDES (RÉFÉRENCE) :	65
5.1.1 Performances de RLDA :	65
5.1.2 Performances de EEGNet :	66
5.1.3 Performances de DeepConvNet :	67
5.2 RÉSULTATS SUR LES DONNÉES À ÉLECTRODES SÈCHES (KAPTICS) :	69
5.2.1 Performances de RLDA :	69
5.2.2 Performances de EEGNet :	70
5.2.3 Performances de DeepConvNet :	72
5.3 COMPARAISON GLOBALE DES PERFORMANCES :	74
5.3.1 Comparaison inter-classifieurs (RLDA vs EEGNet vs DeepConvNet) :	74
5.3.2 Comparaison inter-systèmes (électrodes sèches vs humide) :	77
CHAPITRE 6 DISCUSSION	79
6.1 RÉSULTATS SUR LES DONNÉES À ÉLECTRODES HUMIDES :	79
6.1.1 Performance des classifieurs et comparaison inter-méthodes :	79
6.1.2 Effet de l'accumulation des sessions :	80
6.1.3 Robustesse face à la qualité du signal :	81
6.1.4 Comparaison avec les travaux existants :	81
6.2 RESULTATS SUR LES DONNEES A ELECTRODES SECHES (KAPTICS) :	82
6.2.1 Performance des classifieurs :	82
6.2.2 Impact de la qualité du signal sur la classification :	83
6.3 COMPARAISON INTER-SYSTEMES (ELECTRODES SECHES VS HUMIDES) :	84
6.3.1 Performances relatives des trois classifieurs :	84
6.3.2 Comparaison avec la littérature :	85
6.3.3 Faisabilité clinique des électrodes seches :	86
6.4 LIMITES DE L'ÉTUDE :	86
6.4.1 Contraintes liées aux données à électrodes humides :	87
6.4.2 Données manquantes et runs incomplets :	87
6.4.3 Contraintes liées au protocole Kaptics :	88
6.4.4 Portée des conclusions :	88
CONCLUSION	90
ANNEXE I ANALYSE DE LA QUALITÉ DES DONNÉES EEG ET SÉLECTION DES SUJETS	91
I.1 CRITÈRES D'ÉVALUATION DES SUJETS	91
I.2 RÉSULTATS DÉTAILLÉS DE SÉLECTION	91
ANNEXE II RÉSULTATS COMPLÉMENTAIRES DE CLASSIFICATION	93

	7
II.1 PERFORMANCES SELON LES CONFIGURATIONS DE SESSIONS	93
II.2 COURBES D'ENTRAÎNEMENT :	94
ANNEXE III PARAMÈTRES DES MODÈLES DE CLASSIFICATION.....	96
III.1 PARAMÈTRES DU MODÈLE RLDA	96
III.2 PARAMÈTRES DU MODÈLE EEGNET :	96
III.3 PARAMÈTRES DU MODÈLE DEEPCONVNET.....	97
ANNEXE IV	99
APPENDICE A SCRIPTS DÉVELOPPÉS ET DÉTAILS D'IMPLÉMENTATION	101
LISTE DE RÉFÉRENCES BIBLIOGRAPHIQUES.....	102

LISTE DES TABLEAUX

	Page
Tableau 1 : Tableau des principales bandes de fréquence du signal EEG et leur pertinence pour les BCI basées sur l'imagerie motrice. Adapté de Newson et Thiagarajan (2019) et Pfurtscheller et Neuper (2001).	24
Tableau 2 : Comparaison entre électrodes humides et électrodes sèches.	27
Tableau 3 : Comparaison des hyperparamètres utilisés pour l'entraînement des architectures EEGNet et DeepConvNet.	62
Tableau 4 : Performances moyennes RLDA selon les configurations d'entraînement.	65
Tableau 5 : Résultats de la recherche d'hyperparamètres EEGnet.	66
Tableau 6 : Performances moyennes EEGNet selon les configurations d'entraînement.	67
Tableau 7 : Résultats de la recherche d'hyperparamètres DeepConvNet.	68
Tableau 8 : Performances moyennes DeepConvNet selon les configurations d'entraînement.	68
Tableau 9 : Accuracy globale RLDA par sujet.	69
Tableau 10 : Accuracy globale EEGNet sur cinq jeux de données EEG.	71
Tableau 11 : Accuracy globale DeepConvNet par sujet (validation LORO, données Kaptics).	73
Tableau 12 : Précision des modèles RLDA, EEGNet et DeepConvNet pour différentes configurations de données sur les électrodes humides.	74
Tableau 13 : Comparaison des accuracies moyennes entre systèmes à électrodes humides et sèches (Kaptics).	77

LISTE DES FIGURES

	Page
Figure 1 : Pipeline de traitement d'un système BCI-EEG pour le contrôle d'un avatar en réalité virtuelle. Source : auteure, adapté de Wolpaw et al. (2002).	19
Figure 2 : Localisation des électrodes selon le degré d'invasivité des systèmes BCI. Source : auteure, adapté de Daly et Wolpaw (2008).	20
Figure 3 : Exemples de signaux cérébraux associés aux trois principales stratégies de contrôle BCI. Source : auteure, adapté de Wolpaw et al. (2002).	21
Figure 4 : Modes de fonctionnement des systèmes BCI. Source : auteure, adapté de Alchalabi et al. (2021a).	22
Figure 5 : Disposition des électrodes selon le système international 10-20, vue supérieure du crâne. Les électrodes C3, Cz et C4 (en rouge) correspondent aux sites d'intérêt pour l'imagerie motrice dans le cadre du présent projet. Figure générée par l'auteure.	23
Figure 6 : Courbes d'ERD/ERS enregistrées aux électrodes C3 et C4 pendant l'imagerie motrice de la main gauche (trait épais) et de la main droite (trait fin), dans les bandes alpha (panneau supérieur) et bêta (panneau inférieur).	25
Figure 7 : Comparaison des deux systèmes d'acquisition EEG utilisés dans ce projet. À gauche, le casque à électrodes humides avec transmission filaire. À droite, le casque à électrodes sèches Kaptics avec transmission sans fil. Photos de l'auteure.	26
Figure 8 : Représentation des deux perspectives de l'imagerie motrice. (A) Perspective visuelle à la troisième personne, dans laquelle l'individu se voit réaliser le mouvement. (B) Perspective kinesthésique à la première personne, dans laquelle l'individu ressent le mouvement de l'intérieur.	28
Figure 9 : Activations cérébrales observées lors de différentes tâches locomotrices imaginées. L'augmentation de la complexité de la tâche (station debout, initiation de la marche, marche et marche avec obstacles) s'accompagne d'un recrutement progressif de régions impliquées dans la planification motrice et le traitement visuospatial. Adapté de Malouin et al. (2003).	29
Figure 10 : Boucle de fonctionnement d'une interface cerveau-ordinateur en réadaptation motrice et exemples de modalités de rétroaction sensorielle.	35
Figure 11 : Séquence temporelle d'un essai d'imagerie motrice, illustrant les quatre phases : repos initial (2–3 s), présentation de la flèche directionnelle (~3 s), imagerie motrice avec déplacement de l'avatar (3–4 s) et repos inter-essai (~2 s).	42

Figure 12 : Vue à la première personne de l'environnement virtuel, montrant les membres inférieurs de l'avatar tels que perçus par le participant.....	43
Figure 13 : Les signaux EEG ont été enregistrés à l'aide d'un système Smart BCI, composé d'un bonnet EEG équipé de 19 électrodes Ag/Cl.	45
Figure 14 : Installation du casque de réalité virtuelle Oculus Rift par-dessus le bonnet EEG Smart BCI.	45
Figure 15 : Composants du système Kaptics intégré au casque de réalité virtuelle, montrant les 16 électrodes sèches, le module de traitement et transmission, et le bras de maintien réglable.	46
Figure 16 : Disposition des 16 électrodes du système Kaptics sur les régions centrales et centro-frontales du scalp, ciblant les rythmes sensorimoteurs associés à l'imagerie motrice des membres inférieurs.....	47
Figure 17 : Exemple de sortie du script de monitoring en temps réel : écart-type par canal avec les seuils de qualité BON (10 μ V) et MOYEN (5 μ V).	48
Figure 18 : Densité spectrale de puissance (PSD) des canaux moteurs C3, Cz et C4, calculée par la méthode de Welch. Les bandes de fréquence Delta, Theta, Mu, Beta et Gamma sont indiquées par les zones colorées. Les bandes Mu (8-13 Hz) et Beta (13-30 Hz), encadrée en bleu et vert, sont les plus pertinentes pour l'imagerie motrice.	49
Figure 19 : Exemple de désynchronisation liée à l'événement (ERD) dans la bande mu (8-13 Hz) pour les canaux moteurs Cz, C3 et C4 d'un essai. Les zones colorées indiquent les bandes de fréquence (Thêta, Mu, Beta, Gamma). Une valeur négative traduit une désynchronisation (activité motrice détectable), une valeur positive une synchronisation. Les trois styles de trait correspondent aux trois classes d'imagerie motrice.	50
Figure 20 : Vue d'ensemble comparative des deux pipelines de prétraitement (Kaptics et humide).....	51
Figure 21 Effet des quatre étapes de la chaîne de filtrage Kaptics sur un signal synthétique illustratif.	53
Figure 22 : Principe de la segmentation en epochs.....	53
Figure 23 : Décomposition temporelle d'un essai d'imagerie motrice pour le système Kaptics.	54
Figure 24 : Représentation schématique illustrative de l'analyse par fenêtre glissante.	55
Figure 25 : Effet de la normalisation z-score par canal (illustration schématique).	57

Figure 26 : Pipeline d'extraction de features et de classification RLDA (données Kaptics).	58
Figure 27 : Bandes de fréquence utilisées pour l'extraction de features PSD (données Kaptics, signal synthétique illustratif).	59
Figure 28 : Schéma de la stratégie de validation croisée Leave-One-Run-Out (LORO) utilisée pour l'évaluation des modèles. À chaque itération, un run est réservé au test tandis que les neuf autres sont utilisés pour l'entraînement ; la performance finale correspond à la moyenne des 10.	63
Figure 29 : Représentation schématique des métriques de classification précision, rappel et score F1, ainsi que de leurs relations avec les vrais positifs, faux positifs et faux négatifs.	64
Figure 30 : Résultats de classification RLDA pour le Sujet 01.	70
Figure 31 : Résultats de classification EEGNet (Sujet 01)	72
Figure 32 : Résultats de classification DeepConvNet (Sujet 01).	73
Figure 33 : Courbes d'entraînement et de validation EEGNet pour Subj05, configuration Jour 1. Gate (gauche) : convergence à l'epoch 102. Expert (droite) : surapprentissage visible entre les courbes d'entraînement et de validation sur la tâche à trois classes.	75
Figure 34 : Courbes d'entraînement et de validation DeepConvNet pour Subj05, configuration Jour 1. Gate (gauche) : convergence rapide à l'epoch 37. Expert (droite) : convergence à l'epoch 83 avec courbes train/val proches, indiquant une bonne généralisation.	75
Figure 35 : Courbes d'entraînement et de validation pour EEGNet (haut) et DeepConvNet (bas) sur le Sujet 01 (données Kaptics).	77

LISTE DES ABRÉVIATIONS, SIGLES ET ACRONYMES

AVC	Accident vasculaire cérébral
BCI	Brain-Computer Interface
BCI_STEPS	Tâche de classification des pas (gauche/droite/repos)
BCI_WALK	Tâche de classification marche vs repos
CAR	Common Average Reference
CNN	Convolutional Neural Network (réseau de neurones convolutif)
CRCHUM	Centre de recherche du Centre hospitalier de l'Université de Montréal
CSP	Common Spatial Pattern (patrons spatiaux communs)
EEG	Électroencéphalographie
ERD	Event-Related Desynchronization (désynchronisation liée à l'événement)
ERS	Event-Related Synchronization (resynchronisation liée à l'événement)
FBCSP	Filter-Bank Common Spatial Pattern
ICA	Independent Component Analysis (analyse en composantes indépendantes)
LDA	Linear Discriminant Analysis
LORO	Leave-One-Run-Out
MARA	Multiple Artifact Rejection Algorithm
NPZ	Format de fichier NumPy compressé
PSD	Power Spectral Density
PSDAG	Features spectrales du pipeline original d'Alchalabi et al.
RLDA	Regularized Linear Discriminant Analysis
SMR	Sensorimotor Rhythm
STD	Écart-type (standard deviation)
VR	Virtual Reality

LISTE DES SYMBOLES ET UNITÉS DE MESURE

Hz Hertz

μV Microvolt

$\text{k}\Omega$ Kiloohm

$\text{M}\Omega$ Mégaohm

INTRODUCTION

Les maladies neurologiques affectant la motricité, qu'il s'agisse d'accidents vasculaires cérébraux, de lésions médullaires ou d'autres pathologies du système nerveux central, laissent souvent des séquelles motrices durables chez les patients touchés.

Parmi les déficits les plus invalidants figure la perte de la capacité à marcher, qui a un impact directement l'autonomie et la qualité de vie des patients. Dans ce contexte, la réadaptation motrice constitue un enjeu clinique majeur car les approches thérapeutiques conventionnelles peinent à maintenir l'engagement du patient et à personnaliser le suivi.

Les interfaces cerveau-ordinateur (BCI) permettent de répondre en partie à ces limites. En captant et décodant l'activité cérébrale en temps réel, ces systèmes permettent de traduire les intentions de mouvement d'un patient en commandes directes pour des environnements interactifs, sans nécessiter d'action musculaire volontaire. Couplées à des environnements de réalité virtuelle (VR), les BCI permettent des protocoles de rééducation plus immersifs et motivants, où le patient contrôle un avatar dont les mouvements sont pilotés par son activité cérébrale.

Sur le plan du matériel, l'électroencéphalographie (EEG) est la technologie la plus utilisée dans les BCI non invasives. Peu coûteuse, portable et à haute résolution temporelle, elle permet de capter les signaux électriques générés par l'activité corticale, notamment les rythmes mu et bêta associés à l'imagerie motrice. Les systèmes EEG traditionnels à électrodes humides qui nécessitent l'application d'un gel conducteur et une préparation minutieuse du scalp restent toutefois peu adaptés à un usage clinique courant : le temps d'installation est long, l'inconfort pour le patient réel, et le déploiement dépend souvent d'un personnel formé.

Les casques à électrodes sèches offrent une alternative : sans gel conducteur, ils réduisent considérablement le temps de préparation. Leur facilité d'utilisation est un atout clair pour un contexte clinique, mais leur capacité à produire un signal EEG assez propre pour un système BCI fiable reste à démontrer.

En ce qui concerne le décodage des intentions motrices, le choix de l'algorithme de classification est tout aussi déterminant. Les méthodes classiques telles que l'analyse discriminante linéaire

régularisée (RLDA) sont robustes et bien établies dans la littérature, tandis que les architectures d'apprentissage profond comme EEGNet, DeepConvNet offrent des performances potentiellement supérieures sur des données complexes. Ces deux questions restent toutefois liées : la qualité du signal capté par le matériel conditionne directement la capacité des algorithmes à reconnaître les intentions motrices, et une méthode de classification robuste pourrait en partie compenser les limites du matériel.

Ce projet compare un système à électrodes sèches à un système de référence à électrodes humides, sur une tâche d'imagerie motrice liée à la marche, avec trois méthodes de classification : RLDA, EEGNet et DeepConvNet.

0.1 Contexte de la recherche

Développé au sein du Laboratoire d'innovation orthopédique du Centre de recherche du Centre hospitalier de l'Université de Montréal (CRCHUM), ce projet vise à concevoir des outils de réadaptation motrice accessibles et adaptés aux réalités cliniques. Les travaux reposent sur la continuité d'un système BCI à électrodes humides développé dans le cadre d'une thèse doctorale (Alchalabi et al., 2021).

Ce système utilisait un casque EEG à électrodes humides (Smart BCI, Mitsar, Russie), 19 électrodes Ag/Cl selon le système 10-20, couplé à un environnement de réalité virtuelle sous Unity. Vingt participants sains, âgés de 18 à 45 ans, ont réalisé des tâches d'imagerie motrice de la marche sur quatre sessions. Le système fonctionnait en temps réel : les participants imaginaient un pas gauche, droit ou un mouvement de marche, et leur activité cérébrale était décodée en direct pour contrôler un avatar. Deux classifieurs RLDA, recalibrés après chaque session, atteignaient une précision moyenne de $86,0 \pm 6,1$ % hors ligne. Les données de ce projet, sous forme de segments EEG prétraités et de features spectrales précalculées, servent de base de référence pour le pipeline à électrodes humides.

Ce projet s'appuie sur ces travaux en ajoutant deux éléments : un casque à électrodes sèches (Kaptics, 16 électrodes), avec de nouvelles acquisitions EEG auprès de sujets sains lors de tâches d'imagerie motrice similaires, et la comparaison de trois méthodes de classification (RLDA, EEGNet, DeepConvNet) plutôt qu'une seule. Les acquisitions actuelles portent sur des sujets sains, avec pour objectif d'étendre à terme le protocole à des patients en rééducation de la marche.

L'environnement de réalité virtuelle permet pour l'instant de visualiser un avatar contrôlé manuellement ; l'objectif à terme est de le piloter directement à partir de l'activité cérébrale du patient.

0.2 Problématique

Malgré les avancées dans le domaine des BCI basées sur l'EEG, deux questions freinent encore leur usage en clinique. D'une part, les systèmes à électrodes humides restent performants, mais leur installation reste peu compatible avec un usage régulier en milieu de soins. Les systèmes à électrodes sèches, plus accessibles, n'ont pas encore prouvé qu'ils produisent un signal assez fiable pour une application BCI.

D'autre part, les architectures d'apprentissage profond comme EEGNet et DeepConvNet ont montré de bons résultats sur des données de haute qualité, mais leur comportement face à un signal dégradé, et leur comparaison avec RLDA dans ce contexte, restent peu étudiés. Ce projet évalue ces deux dimensions ensemble, matériel et méthode de classification, pour identifier la combinaison la plus adaptée à un usage clinique.

0.3 Objectif du projet

Ce projet vise à évaluer la faisabilité d'un système BCI EEG pour contrôler un avatar en réalité virtuelle dans un contexte de réadaptation de la marche. Il compare deux matériels d'acquisition et trois méthodes de classification. Pour les données Kaptics, acquises auprès d'un nombre restreint de participants, l'évaluation constitue une preuve de concept plutôt qu'une validation statistique généralisable. Quatre objectifs en découlent :

- Développer un pipeline de prétraitement EEG (filtrage, segmentation, rejet d'artefacts, normalisation) ;
- Implémenter EEGNet et DeepConvNet sur les données de référence à électrodes humides, pour établir une base de comparaison ;
- Acquérir de nouvelles données avec le casque à électrodes sèches Kaptics et valider qualitativement le signal produit ;

- Comparer RLDA, EEGNet et DeepConvNet sur ces données Kaptics, à titre de preuve de concept, pour obtenir une première indication de la combinaison casque-algorithme la plus adaptée.

0.4 Organisation du mémoire

Ce mémoire est organisé en six chapitres. Le chapitre 1 présente les notions fondamentales nécessaires à la compréhension du projet : les interfaces cerveau-ordinateur, les signaux EEG, l'imagerie motrice et les méthodes de classification utilisées. Le chapitre 2 constitue la revue de littérature, examinant les performances des BCI en contexte de réadaptation motrice, le décodage des intentions motrices de la marche, et les résultats obtenus avec les différentes architectures de classification. Le chapitre 3 décrit les deux systèmes d'acquisition et le protocole expérimental, avec une validation détaillée du signal produit par le casque à électrodes sèches Kaptics. Le chapitre 4 expose les deux pipelines de prétraitement et les trois algorithmes de classification mis en œuvre, en précisant pour chacun les choix d'implémentation retenus pour les données Kaptics et les données humides. Le chapitre 5 présente et compare les résultats obtenus pour chaque combinaison casque-algorithme. Enfin, le chapitre 6 discute ces résultats en lien avec les enjeux cliniques et aborde les perspectives de recherche et de déploiement en réadaptation motrice.

0.5 Déclaration sur l'utilisation de l'intelligence artificielle :

Un assistant IA (Claude, Anthropic) a été utilisé pendant la rédaction de ce mémoire, surtout pour reformuler certains passages, structurer quelques chapitres et chercher des références bibliographiques (section 6.3.2 notamment). Les données, les analyses et les conclusions présentées viennent du travail de l'auteure.

CHAPITRE 1

NOTIONS FONDAMENTALES

1.1 Interface cerveau – ordinateur :

Une interface cerveau-ordinateur (BCI) est un système de communication qui établit un lien direct entre le cerveau et un dispositif externe, en captant et interprétant l'activité cérébrale en temps réel pour la convertir en commandes de contrôle, sans nécessiter de mouvement musculaire volontaire (Wolpaw et al., 2002). Depuis les premiers travaux de Vidal dans les années 1970, la recherche dans ce domaine a connu une croissance importante, stimulée par les progrès conjoints en neuroimagerie, en traitement du signal et en apprentissage automatique. Leurs applications couvrent aujourd'hui un spectre large, allant du contrôle de curseurs informatiques et de prothèses robotiques jusqu'au pilotage d'avatars en réalité virtuelle, ce dernier usage étant au cœur du système développé par Alchalabi et al. (2021a).

Dans le domaine clinique, les BCI permettent d'agir sur la réadaptation neurologique, notamment chez les personnes ayant subi un accident vasculaire cérébral ou une lésion de la moelle épinière (Daly et Wolpaw, 2008). Plus récemment, des travaux ont exploré leur utilisation chez des personnes atteintes de syndrome d'enfermement (locked-in syndrome), pour lesquelles les BCI représentent parfois le seul canal de communication disponible (Brumberg et al., 2016).

1.1.1 Principe des BCI :




Figure 1 : Pipeline de traitement d'un système BCI-EEG pour le contrôle d'un avatar en réalité virtuelle. Source : auteure, adapté de Wolpaw et al. (2002).

Le fonctionnement d'une BCI repose sur un pipeline de traitement qui transforme l'activité cérébrale brute en commandes exécutables (Wolpaw et al., 2002). Ce processus débute par l'acquisition du signal cérébral, suivie d'une phase de prétraitement visant à éliminer les artefacts et à isoler les composantes d'intérêt. Les caractéristiques pertinentes sont ensuite extraites du signal purifié, il peut s'agir par exemple, de la puissance spectrale dans les bandes mu et beta au-dessus du cortex sensorimoteur avant d'être transmises à un algorithme de classification qui les traduit en commandes concrètes pour l'application cible (Daly et Wolpaw, 2008). Une erreur ou une perte d'information à n'importe laquelle de ces étapes se répercute directement sur la performance globale du système.

L'efficacité d'une BCI dépend d'un double apprentissage. L'utilisateur doit apprendre à produire des signaux cérébraux stables et distincts pour que le classifieur puisse les reconnaître ; le système, de son côté, doit s'ajuster aux caractéristiques propres au signal de chaque personne (Daly et Wolpaw, 2008). Pour les BCI basées sur l'imagerie motrice, cette co-adaptation se fait généralement sur plusieurs sessions, le classifieur étant recalibré au fur et à mesure que de nouvelles données sont acquises.

1.1.2 Types de BCI :

Les BCI se distinguent selon plusieurs critères : leur degré d'invasivité, la stratégie mentale utilisée pour les contrôler et leur mode de fonctionnement.




Figure 2 : Localisation des électrodes selon le degré d'invasivité des systèmes BCI. Source : auteure, adapté de Daly et Wolpaw (2008).

Sur le plan de l'invasivité, Daly et Wolpaw (2008) distinguent trois catégories (Figure 2). Les BCI invasives, avec des électrodes implantées dans le tissu cortical, offrent la meilleure résolution spatiale et le meilleur rapport signal-bruit, mais comportent des risques chirurgicaux qui les réservent à des applications cliniques spécifiques. Les BCI semi-invasives, comme l'électrocorticographie (ECoG), placent les électrodes à la surface du cortex, offrant un compromis entre qualité du signal et invasivité. Les BCI non invasives, dont l'EEG est l'exemple le plus répandu, reposent sur des capteurs placés sur le scalp : leur résolution spatiale est plus faible, mais leur caractère non chirurgical, leur coût modéré et leur facilité de déploiement en font le choix privilégié pour les applications cliniques (Wolpaw et al., 2002).




Figure 3 : Exemples de signaux cérébraux associés aux trois principales stratégies de contrôle BCI. Source : auteure, adapté de Wolpaw et al. (2002).

Sur le plan de la stratégie mentale, les systèmes basés sur l'EEG exploitent principalement trois phénomènes neurophysiologiques (Figure 3) : les potentiels évoqués P300, une réponse positive apparaissant environ 300 ms après un stimulus ayant attiré l'attention ; les potentiels corticaux lents (SCP), des variations de tension associées à l'activation ou l'inhibition de régions corticales ; et les rythmes sensorimoteurs μ (8-12 Hz) et β (16-30 Hz), des oscillations dont l'amplitude change lors de mouvements réels ou imaginés (Wolpaw et al., 2002 ; Daly et Wolpaw, 2008). Parmi ces paradigmes, l'imagerie motrice est particulièrement adaptée à la réadaptation motrice, car elle

engage directement les mécanismes neuronaux liés aux intentions de mouvement, sans stimulation externe (Pfurtscheller et Neuper, 2001).




Figure 4 : Modes de fonctionnement des systèmes BCI. Source : auteure, adapté de Alchalabi et al. (2021a).

Sur le plan du mode de fonctionnement (Figure 4), les BCI synchrones (cue-paced) guident l'utilisateur par un stimulus externe indiquant quand produire l'imagerie motrice, tandis que les BCI asynchrones (self-paced) laissent l'utilisateur générer librement son pattern mental. Ces dernières se subdivisent en mode à commutateur (switch-control), avec un retour discret après chaque classification correcte, et en mode continu (continuous-control), où le retour est maintenu tant que l'imagerie est soutenue (Alchalabi et al., 2021a). Le mode synchrone convient mieux aux phases initiales de l'apprentissage, tandis que le mode asynchrone continu s'impose lorsque le patient progresse vers un contrôle plus naturel du mouvement.

L'EEG, en particulier, occupe une place centrale dans les BCI modernes grâce à sa résolution temporelle, son faible coût et sa portabilité, ses caractéristiques sont détaillées dans la section suivante.

1.2 Signaux électroencéphalographiques (EEG) :

L'électroencéphalographie est une technique de mesure de l'activité électrique cérébrale à partir d'électrodes posées sur le cuir chevelu. Ces électrodes captent les variations de potentiel électrique produites lorsque de grandes populations de neurones du cortex cérébral s'activent simultanément. Grâce à sa très bonne résolution temporelle, son caractère non invasif et sa relative facilité de mise en œuvre, l'EEG est aujourd'hui la modalité d'acquisition la plus utilisée dans le domaine des BCI (Wolpaw et al., 2002 ; Alchalabi et al., 2019).

1.2.1 Acquisition des signaux EEG :




Figure 5 : Disposition des électrodes selon le système international 10-20, vue supérieure du crâne. Les électrodes C3, Cz et C4 (en rouge) correspondent aux sites d'intérêt pour l'imagerie motrice dans le cadre du présent projet. Figure générée par l'auteure.

Le positionnement des électrodes suit généralement le système international 10-20 (Figure 5), qui définit 19 à 21 sites à partir de repères anatomiques crâniens (nasion, inion, apophyses mastoïdes), espacés de 10 % ou 20 % des distances totales entre ces repères. Chaque électrode est identifiée par une lettre indiquant la région (F frontale, C centrale, P pariétale, O occipitale, T temporale) et un chiffre indiquant l'hémisphère (pair à droite, impair à gauche, z pour la ligne médiane).

Chaque électrode mesure la différence de potentiel entre son site et une référence commune, souvent placée sur le lobe de l'oreille ou au vertex. La qualité du contact, caractérisée par l'impédance électrode-scalp, doit rester sous 5 k Ω pour les électrodes humides afin de limiter le bruit. Pour les électrodes sèches, cette impédance est naturellement plus élevée en l'absence de

gel conducteur : Hinrichs et al. (2020) rapportent une valeur médiane de 0,4 M Ω , ce qui exige des amplificateurs à très haute impédance d'entrée et un prétraitement adapté.

Le signal brut est ensuite amplifié, filtré analogiquement pour éliminer les composantes hors bande, puis numérisé à une fréquence d'échantillonnage typiquement comprise entre 250 et 1000 Hz (Wolpaw et al., 2002).

Pour les BCI basées sur l'imagerie motrice, les électrodes situées au-dessus des aires sensorimotrices, notamment C3, Cz et C4, sont particulièrement importantes : elles captent l'activité corticale associée aux mouvements réels et imaginés des membres.

1.2.2 Bandes de fréquence EEG :

Le signal EEG est traditionnellement décomposé en plusieurs bandes de fréquence, chacune associée à des états cognitifs ou physiologiques distincts : delta (0,5-4 Hz, sommeil profond), thêta (4-8 Hz, somnolence et méditation), alpha (8-13 Hz, relaxation au repos), bêta (13-30 Hz, cognition active et motricité volontaire) et gamma (au-delà de 30 Hz, processus cognitifs de haut niveau) (Newson et Thiagarajan, 2019).

Tableau 1 : Tableau des principales bandes de fréquence du signal EEG et leur pertinence pour les BCI basées sur l'imagerie motrice. Adapté de Newson et Thiagarajan (2019) et Pfurtscheller et Neuper (2001).

Bande	Fréquence (Hz)	État associé	Pertinence BCI
Delta	0,5–4	Sommeil profond	Faible
Thêta	4–8	Somnolence, méditation	Faible
Alpha	8–13	Repos, yeux fermés	Modérée
Mu	7–13	Imagerie motrice	Élevée
Bêta	13–30	Cognition, motricité	Élevée
Gamma	>30	Processus cognitifs avancés	Faible

Pour l'imagerie motrice, deux sous-bandes générées par le cortex sensorimoteur sont particulièrement importantes : la bande mu (7-13 Hz) et la bande bêta centrale (13-30 Hz). Bien que la bande mu chevauche partiellement la bande alpha en fréquence, elle a une origine

sensorimotrice distincte et réagit spécifiquement aux tâches motrices réelles ou imaginées, contrairement à l'alpha occipital, davantage lié aux processus visuels et attentionnels (Pfurtscheller et Neuper, 2001).




Figure 6 : Courbes d'ERD/ERS enregistrées aux électrodes C3 et C4 pendant l'imagerie motrice de la main gauche (trait épais) et de la main droite (trait fin), dans les bandes alpha (panneau supérieur) et bêta (panneau inférieur).

Ces deux bandes présentent des modulations caractéristiques lors de l'imagerie motrice (Figure 6) : une désynchronisation liée à l'événement (ERD, Event-Related Desynchronization), soit une baisse de puissance spectrale pendant la préparation et l'imagination du mouvement, suivie à la fin de l'acte moteur imaginé d'une resynchronisation (ERS, Event-Related Synchronization), un retour ou une hausse de puissance dans ces mêmes bandes. Pfurtscheller et Neuper (2001) ont montré que cette ERD, similaire à celle observée lors d'un mouvement réel, se produit sur le cortex sensorimoteur contralatéral à la main imaginée, et que la bande bêta récupère plus rapidement après le mouvement que la bande mu.

Ces oscillations constituent le signal d'intérêt principal des BCI basées sur l'imagerie motrice. Dans ce projet, c'est leur détection au niveau des électrodes C3, Cz et C4 qui permet de décoder les intentions de mouvement, que ce soit avec le casque à électrodes humides ou avec le casque Kaptics.

1.2.3 Prétraitement des signaux EEG :

Le signal EEG brut est affecté par de nombreux artefacts, d'origine physiologique (mouvements oculaires, clignements, activité musculaire) ou environnementale (interférences à 60 Hz, bruit des amplificateurs), qu'il faut supprimer avant toute analyse. Le pipeline typique comprend un filtrage passe-bande pour isoler les fréquences d'intérêt, un filtre coupe-bande centré sur la fréquence du réseau électrique, et souvent une étape de suppression des artefacts oculaires par analyse en composantes indépendantes (ICA), la méthode de référence pour cette tâche (Joyce et al., 2004). Dans le pipeline d'Alchalabi et al. (2021a), l'algorithme MARA complète l'ICA pour identifier automatiquement les composantes artéfactuelles ; les choix de prétraitement propres à ce projet sont détaillés au chapitre 4.

1.2.4 Électrodes sèches vs électrodes humides :




Figure 7 : Comparaison des deux systèmes d'acquisition EEG utilisés dans ce projet. À gauche, le casque à électrodes humides avec transmission filaire. À droite, le casque à électrodes sèches Kaptics avec transmission sans fil. Photos de l'auteur.

Les systèmes d'acquisition EEG se distinguent fondamentalement selon le type d'interface électrode-scalp utilisé (Figure 7). Les électrodes humides, ou électrodes à gel, établissent un contact de haute qualité grâce à un gel conducteur qui maintient l'impédance sous 5 k Ω , ce qui en fait la référence pour les enregistrements cliniques. Leur installation reste toutefois longue, incluant l'abrasion cutanée, l'application du gel et la vérification de chaque électrode, une procédure prenant en moyenne six minutes et demie pour dix-neuf canaux et nécessitant un technicien qualifié (Hinrichs et al., 2020). Ce temps de préparation, ainsi que la dépendance à un

personnel formé, freinent leur déploiement en routine clinique, notamment en réadaptation motrice où les sessions sont fréquentes et doivent rester accessibles au personnel soignant.

Les électrodes sèches reposent sur un contact direct entre des pointes métalliques et le scalp, sans gel ni préparation cutanée. Leur installation est nettement plus rapide, environ quatre minutes pour le même nombre de canaux, et elles sont mieux tolérées sur des périodes prolongées, la majorité des sujets leur accordant une préférence marquée dans les études comparatives (Hinrichs et al., 2020). Ces caractéristiques les rendent attractives pour un déploiement en milieu hospitalier, où la simplicité d'utilisation et le confort du patient sont essentiels.

Leur principal inconvénient reste une impédance nettement plus élevée, de l'ordre de 0,4 M Ω en médiane contre moins de 5 k Ω pour les électrodes humides, ce qui accroît la sensibilité aux artefacts de basse fréquence. Hinrichs et al. (2020) ont comparé systématiquement un système sans fil à électrodes sèches et un système conventionnel à électrodes humides chez seize sujets sains et seize patients neurologiques. Les puissances alpha et bêta au repos ne différaient pas significativement entre les deux systèmes, tandis que les bandes delta et thêta présentaient une puissance légèrement supérieure avec les électrodes sèches, probablement due à des artefacts résiduels. Deux neurologues évaluant les tracés en aveugle ont néanmoins jugé les enregistrements comparables entre les deux systèmes. Le Tableau 2 résume les principales différences entre les deux technologies.

Tableau 2 : Comparaison entre électrodes humides et électrodes sèches.

Critère	Électrodes humides	Électrodes sèches
Impédance	< 5 k Ω	~ 0,4 M Ω (médiane)
Temps d'installation	~ 6,5 minutes	~ 4 minutes
Gel conducteur	Requis	Non requis
Technicien qualifié	Nécessaire	Non nécessaire
Qualité du signal (alpha, bêta)	Référence	Comparable
Artefacts basse fréquence	Faibles	Légèrement plus élevés
Confort patient (> 30 min)	Moins bien toléré	Mieux toléré
Application clinique	Standard actuel	Alternative prometteuse

Ces résultats suggèrent que, sous réserve d'un protocole d'installation rigoureux et d'un prétraitement adapté, les électrodes sèches pourraient répondre aux exigences des BCI pour la réadaptation motrice. C'est précisément cette question qui est au cœur du présent projet : le casque

à électrodes sèches Kaptics utilisé au CRCHUM peut-il produire un signal de qualité suffisante pour alimenter les algorithmes de classification EEGNet, DeepConvNet et RLDA, et ainsi constituer une alternative au casque à électrodes humides utilisé dans les travaux antérieurs du laboratoire ?

1.3 Imagerie motrice :

L'imagerie motrice consiste à simuler mentalement un mouvement de façon active, sans qu'aucun mouvement réel ne soit produit (Decety, 1996). Elle peut s'exercer selon une perspective visuelle à la troisième personne, où l'individu se voit effectuer le mouvement, ou une perspective kinesthésique à la première personne, où il en ressent les sensations de l'intérieur (Figure 8) ; cette dernière est généralement considérée comme plus proche de l'exécution réelle (Malouin et Richards, 2010).




Figure 8 : Représentation des deux perspectives de l'imagerie motrice. (A) Perspective visuelle à la troisième personne, dans laquelle l'individu se voit réaliser le mouvement. (B) Perspective kinesthésique à la première personne, dans laquelle l'individu ressent le mouvement de l'intérieur.

Le principe d'équivalence fonctionnelle donne à l'imagerie motrice sa valeur scientifique et clinique : imaginer un mouvement et l'exécuter réellement engagent les mêmes structures neurales, produisent des réponses physiologiques comparables (accélération du rythme cardiaque et de la respiration proportionnelle à l'intensité du mouvement imaginé) et génèrent des signaux cérébraux similaires (Decety, 1996 ; Jeannerod, 2001). Decety (1996) a observé, pendant l'imagination de mouvements sans exécution réelle, des activations du cortex prémoteur, de l'aire motrice supplémentaire, du cervelet et des ganglions de la base. Jeannerod (2001) a montré que ces activations atteignent des niveaux comparables entre mouvement imaginé et mouvement réel, un

mécanisme d'inhibition spinal empêchant la simulation cérébrale de se traduire en mouvement physique involontaire.




Figure 9 : Activations cérébrales observées lors de différentes tâches locomotrices imaginées. L'augmentation de la complexité de la tâche (station debout, initiation de la marche, marche et marche avec obstacles) s'accompagne d'un recrutement progressif de régions impliquées dans la planification motrice et le traitement visuospatial. Adapté de Malouin et al. (2003).

La marche pose toutefois une question distincte : contrairement aux mouvements simples des membres supérieurs étudiés initialement, elle mobilise simultanément l'équilibre, la coordination rythmique des deux jambes, l'adaptation visuelle continue et la régulation posturale du corps entier, en plus de structures sous-corticales comme les ganglions de la base et le cervelet. Malouin et al. (2003) ont confirmé que le principe d'équivalence fonctionnelle s'étend à cette tâche complexe (Figure 9) : imaginer la locomotion active les mêmes régions cérébrales, y compris sous-corticales, que l'exécuter réellement. Ce résultat établit que la marche imaginée génère des signaux cérébraux réels et mesurables, ce qui justifie son utilisation comme paradigme de contrôle en BCI de réadaptation, et constitue le fondement neurophysiologique du présent projet. C'est ce même principe qui explique la présence des désynchronisations ERD dans les bandes mu et bêta (section 1.2.2) : en imaginant un mouvement, l'utilisateur produit des modulations cérébrales réelles et détectables, que le système peut capturer et interpréter comme une commande.

1.4 Méthodes de classification des signaux EEG :

La classification des signaux EEG en BCI repose historiquement sur des méthodes classiques combinant extraction de caractéristiques spatiales et apprentissage supervisé, systématiquement recensées par Lotte et al. (2007) dans une revue couvrant plus d'une vingtaine de classifieurs évalués sur des protocoles standardisés.

1.4.1 Méthodes de classification classiques :

L'analyse discriminante linéaire (LDA) est historiquement l'une des plus utilisées : elle détermine un hyperplan séparant les classes en maximisant la distance entre leurs moyennes tout en minimisant la variance intra-classe. Sa faible complexité computationnelle la rend adaptée aux systèmes temps réel, et sa stabilité face aux variations de l'ensemble d'entraînement constitue un atout face à la nature non stationnaire des signaux EEG. Son principal inconvénient reste sa linéarité, insuffisante pour capturer des structures complexes. Sa version régularisée (RLDA) introduit un paramètre pénalisant la complexité du modèle, ce qui améliore la gestion du bruit et des valeurs aberrantes fréquentes en EEG, et se traduit par de meilleures capacités de généralisation.

Ces approches sont généralement précédées d'un filtrage spatial, nécessaire en raison de la conduction volumique : le signal électrique produit par les neurones se propage à travers les tissus, le crâne et le cuir chevelu avant d'atteindre les électrodes, si bien que chaque électrode capte un mélange de nombreuses sources corticales plutôt que l'activité d'une région précise (Blankertz et al., 2008). Pour l'imagerie motrice, cette limitation est problématique : l'asymétrie hémisphérique entre les rythmes mu et bêta des deux hémisphères, que le classifieur doit détecter pour distinguer une imagerie de main gauche ou droite, se trouve noyée dans l'activité de fond des électrodes voisines sans filtrage adapté.

L'algorithme des patrons spatiaux communs (CSP), développé par Koles (1991) et popularisé par le groupe Berlin BCI (Blankertz et al., 2008), répond à ce besoin en calculant des filtres spatiaux, soit des combinaisons pondérées des électrodes, qui maximisent la variance du signal pour une

condition tout en la minimisant pour l'autre. Cette variance étant directement liée à la puissance du signal dans la bande de fréquence considérée, le CSP isole ainsi les composantes les plus discriminantes entre deux conditions mentales. Les logarithmes des puissances projetées sur ces filtres constituent les caractéristiques transmises au classifieur.

La combinaison CSP + RLDA constitue aujourd'hui la ligne de base incontournable pour les BCI basées sur l'imagerie motrice, et c'est à ce titre qu'elle est utilisée dans ce projet comme point de comparaison face aux architectures d'apprentissage profond présentées dans les sections suivantes.

1.4.2 Approches basées sur l'apprentissage profond :

Face aux limitations des méthodes classiques, notamment leur dépendance à une extraction manuelle de caractéristiques et leur sensibilité à la non-stationnarité des signaux EEG, l'apprentissage profond s'est imposé comme une alternative pour l'analyse automatisée de ces signaux. Roy et al. (2019) ont réalisé une revue systématique de 154 études publiées entre 2010 et 2018, couvrant l'épilepsie, le sommeil, les BCI et la surveillance cognitive et affective.

L'intérêt principal de l'apprentissage profond réside dans sa capacité à apprendre des représentations hiérarchiques directement à partir des données brutes, sans extraction manuelle de caractéristiques, une étape reconnue comme longue et spécialisée pour l'EEG (Roy et al., 2019). Les réseaux composés de couches successives de transformations non linéaires ajustent leurs paramètres automatiquement en minimisant une fonction de coût.

Parmi les architectures appliquées à l'EEG, les réseaux de neurones convolutifs (CNN) sont de loin les plus utilisés : leurs couches de convolution appliquent des filtres appris localement, détectant des motifs temporels ou spatiaux indépendamment de leur position dans le signal, une propriété bien adaptée aux structures récurrentes des états mentaux en EEG. Les réseaux récurrents (RNN, notamment LSTM) représentent environ 13 % des études et modélisent explicitement les dépendances temporelles à long terme ; les autoencodeurs, également environ 13 % des études, servent surtout à apprendre des représentations compactes en mode non supervisé. Les architectures plus profondes exigent en général davantage d'exemples d'entraînement pour éviter le surapprentissage, ce qui reste un défi persistant dans ce domaine.

L'apprentissage profond se heurte à trois défis propres à l'EEG. Le volume de données disponibles, d'abord : quelques dizaines à quelques milliers d'exemples par étude, contre des millions dans les applications classiques du deep learning (Roy et al., 2019). Le faible rapport signal-sur-bruit, ensuite, les artefacts physiologiques (clignements, mouvements musculaires) pouvant dominer le signal d'intérêt. La forte variabilité inter-sujets, enfin, complique la généralisation d'un modèle entraîné sur un groupe à de nouveaux sujets. Ces contraintes expliquent en partie le développement d'architectures compactes conçues spécifiquement pour les BCI, comme EEGNet et DeepConvNet, présentées dans les sections suivantes.

1.4.3 Architecture EEGNet :

EEGNet est un réseau de neurones convolutif compact proposé par Lawhern et al. (2018) spécifiquement pour la classification de signaux EEG en BCI. Son originalité réside dans sa capacité à généraliser à travers différents paradigmes BCI tout en restant entraînable avec peu de données, deux contraintes majeures dans ce domaine.

L'architecture s'organise en deux blocs convolutifs successifs. Le premier applique une convolution temporelle sur l'ensemble des canaux, avec un noyau de longueur égale à la moitié de la fréquence d'échantillonnage (64 points à 128 Hz), extrayant des filtres passe-bande à partir de 2 Hz, suivie d'une convolution en profondeur (depthwise convolution) qui apprend un filtre spatial propre à chaque filtre temporel. Cette séquence, inspirée de l'algorithme FBCSP (Filter-Bank Common Spatial Pattern), extrait des filtres spatiaux spécifiques à chaque bande de fréquence tout en limitant le nombre de paramètres à entraîner. Le second bloc utilise une convolution séparable, combinant une convolution en profondeur sur 500 ms d'activité EEG et une convolution point à point, pour résumer les cartes de caractéristiques du premier bloc. Une couche de classification softmax complète l'architecture.

L'atout principal d'EEGNet est sa compacité : selon les configurations testées (EEGNet-4,2 et EEGNet-8,2), le modèle ne compte que 1 000 à 2 300 paramètres entraînaibles, deux ordres de grandeur de moins que DeepConvNet et ShallowConvNet, auxquels il est comparé dans l'article. Cette compacité limite le risque de surapprentissage même avec des données d'entraînement restreintes, une situation fréquente en EEG.

Dans ce projet, EEGNet est appliqué à la classification d'imagerie motrice de la marche à partir de deux systèmes d'électrodes distincts. L'architecture originale a toutefois été adaptée à une structure hiérarchique à deux étages (gate + expert), détaillée au chapitre 4, pour répondre aux contraintes spécifiques des données disponibles.

1.4.4 Architecture DeepConvNet :

DeepConvNet est une architecture de réseau de neurones convolutif profond proposée par Schirrneister et al. (2017), dans une étude comparative visant à évaluer la capacité des réseaux convolutifs à décoder des signaux EEG en apprentissage de bout en bout (end-to-end), directement à partir des données brutes sans extraction manuelle de caractéristiques.

L'architecture se compose de quatre blocs convolutifs successifs, chacun constitué d'une convolution suivie d'une normalisation par lots, d'une non-linéarité ELU, d'un pooling maximal et d'un dropout. Le premier bloc se distingue par deux couches séparées : une convolution temporelle appliquée à chaque canal indépendamment, suivie d'une convolution spatiale portant sur l'ensemble des électrodes. Cette séparation, inspirée de la logique du FBCSP (Filter-Bank Common Spatial Pattern), diffère structurellement d'une convolution unique. Les blocs suivants appliquent des convolutions temporelles avec un nombre croissant de filtres (25, 50, 100, puis 200 unités ELU) et des couches de pooling de stride 3, pour extraire progressivement des caractéristiques plus abstraites. Une couche dense avec activation softmax assure la classification finale.

Par rapport à EEGNet, DeepConvNet contient environ deux ordres de grandeur plus de paramètres entraînaables (environ 170 000 selon la configuration), ce qui le rend plus gourmand en données et plus sensible au surapprentissage lorsque celles-ci sont limitées, un désavantage particulièrement marqué en classification intra-sujet, où EEGNet tend à le surpasser.

Dans ce projet, DeepConvNet est appliqué en parallèle d'EEGNet à la classification de l'imagerie motrice de la marche sur les deux systèmes d'acquisition. Une stratégie d'augmentation des données a été mise en œuvre pour compenser la taille limitée des jeux de données disponibles ; les détails de cette adaptation sont présentés au chapitre 4.

CHAPITRE 2

REVUE DE LITTÉRATURE

Ce chapitre présente maintenant l'état de la recherche dans ces domaines, en s'appuyant sur les études empiriques qui ont évalué les performances des BCI dans des contextes cliniques et expérimentaux, et en situant le présent projet par rapport aux travaux existants.

2.1 BCI pour la réadaptation motrice :

Les BCI de réadaptation motrice reposent sur un principe commun : détecter l'intention de mouvement du patient à partir de son activité cérébrale et lui fournir immédiatement un retour visuel ou sensoriel en réponse, par exemple le mouvement d'un exosquelette, d'une prothèse ou d'un avatar virtuel. Ce lien direct entre ce que le cerveau produit et ce que le patient perçoit est considéré comme le mécanisme central favorisant la neuroplasticité et la récupération motrice. Ce principe, initialement démontré pour des mouvements simples des membres supérieurs, s'est progressivement étendu à des applications plus complexes. Brumberg et al. (2016) ont ainsi montré que les modulations du rythme sensorimoteur induites par l'imagerie motrice permettent non seulement de contrôler des curseurs, mais également de synthétiser directement des sons de parole, illustrant la polyvalence de ce paradigme au-delà de la seule réadaptation motrice.

2.1.1 Applications cliniques des BCI en réadaptation motrice :

Les BCI sont explorées comme outil de réadaptation motrice chez des personnes présentant un déficit neurologique d'origines variées : AVC, lésion médullaire, ou toute autre atteinte du contrôle volontaire du mouvement. Le couplage entre détection de l'intention motrice et retour sensoriel immédiat (exosquelette, stimulation électrique, avatar virtuel) est considéré comme le mécanisme central de la récupération motrice, en réactivant les boucles sensorimotrices endommagées (Cervera et al., 2018 ; Figure 10).




Figure 10 : Boucle de fonctionnement d'une interface cerveau-ordinateur en réadaptation motrice et exemples de modalités de rétroaction sensorielle.

Cervera et al. (2018), dans une méta-analyse de neuf essais randomisés (235 patients post-AVC), utilisent principalement l'échelle de Fugl-Meyer pour évaluer la capacité de mouvement volontaire du bras et de la main. Les groupes contrôles recevaient soit la thérapie habituelle, soit un robot déplaçant le bras passivement, soit un retour factice sans lien avec l'activité cérébrale, ce qui permet d'isoler la contribution du couplage cerveau-retour sensoriel. L'entraînement BCI est associé à une différence standardisée des moyennes de 0,79 par rapport aux contrôles, une taille d'effet entre moyenne et grande ; dans six des neuf études, les gains dépassaient le seuil de changement cliniquement perceptible (5,25 points). Plusieurs études rapportent aussi des modifications de la connectivité fonctionnelle, suggérant une réorganisation corticale réelle plutôt qu'un simple effet d'entraînement.

Ang et al. (2014) ont comparé, chez 21 patients en AVC chronique, une BCI couplée à un robot haptique, le robot seul, et la thérapie standard : le groupe BCI a montré des gains moteurs significativement supérieurs à 3, 12 et 24 semaines, maintenus sur toute la période de suivi.

Les BCI servent aussi de systèmes assistifs pour restaurer directement des fonctions perdues. Soekadar et al. (2016) rapportent qu'un exosquelette de main contrôlé par un système hybride EEG/électrooculographie a permis à six personnes quadriplégiques de réaliser de façon autonome des activités quotidiennes hors laboratoire, avec une fonction manuelle atteignant 85 % du score maximal.

Dans le domaine spécifique de la marche, Alchalabi et al. (2021a) ont développé un système BCI multimodal permettant à vingt participants sains de contrôler les pas et la marche d'un avatar en réalité virtuelle par imagerie motrice à la première personne, avec un protocole co-adaptatif sur quatre sessions. Les performances atteignaient 83 % en mode à commutateur et 92 % en mode continu ; le recalibrage séquentiel des classifieurs après chaque session a fait passer la précision en ligne de 65,8 % en fin de Jour 2 à 74,7 % en début de Jour 3.

2.1.2 Réalité virtuelle dans les BCI :

Parmi les modalités de retour sensoriel utilisées en réadaptation BCI, la réalité virtuelle occupe une place croissante grâce à sa capacité à offrir un environnement immersif et contrôlé. Cervera et al. (2018) distinguent un retour abstrait, comme un curseur se déplaçant sur un écran, d'un retour incarné, où l'utilisateur voit une représentation de son propre corps en mouvement dans l'environnement virtuel. Cette seconde approche renforce le sentiment d'agentivité, soit la sensation d'être l'auteur du mouvement, considéré comme un facteur favorisant la neuroplasticité et l'apprentissage moteur.

Vourvopoulos et al. (2019) ont évalué un système BCI basé sur l'imagerie motrice couplé à un environnement immersif pour la réadaptation du membre supérieur chez des patients post-AVC. Les participants visualisaient un avatar de leur bras effectuant les mouvements imaginés, le système détectant en temps réel les modulations EEG associées et déclenchant le mouvement en réponse. Les résultats ont montré des améliorations significatives de la fonction motrice (échelle de Fugl-Meyer), accompagnées de modifications de l'activité cérébrale en imagerie fonctionnelle, suggérant une réorganisation des réseaux moteurs corticaux.

Au-delà de la neuroplasticité, la réalité virtuelle favorise aussi la motivation et l'engagement du patient : elle permet de varier les tâches et d'adapter la difficulté en temps réel, ce qui contre la monotonie des exercices, un frein reconnu à l'adhésion thérapeutique. C'est dans cette perspective que s'inscrit ce projet, où un avatar en réalité virtuelle immersive constitue l'interface de retour sensoriel pour le contrôle BCI basé sur l'imagerie motrice de la marche.

2.2 Décodage des intentions motrices de la marche :

Le décodage des intentions motrices à partir du signal EEG dans le contexte de la marche a fait l'objet de plusieurs études. Les modulations ERD/ERS dans les bandes mu et bêta au-dessus du cortex sensorimoteur, détaillées au Chapitre 1, constituent le signal d'intérêt principal. La question centrale est de savoir si ces modulations, bien documentées pour des mouvements simples des membres supérieurs, restent suffisamment discriminables pour une classification fiable dans le contexte plus complexe de la marche.

Malouin et al. (2003) ont demandé à six adultes sains d'imaginer quatre tâches locomotrices de complexité croissante (rester debout, initier la marche, marcher à allure régulière, marcher en évitant des obstacles). Imaginer la marche activait un réseau cérébral étendu, comprenant le cortex prémoteur dorsal, le cortex préfrontal dorsolatéral et le lobule pariétal inférieur, soit les mêmes régions impliquées dans la planification du mouvement réel, ainsi que le noyau caudé, connu pour son rôle dans les mouvements automatiques et rythmiques. Le réseau recruté s'élargissait avec la complexité de la tâche, incluant des régions liées au traitement visuospatial. Ces résultats confirment que la marche imaginée engage des circuits cérébraux réels et mesurables, ce qui justifie son utilisation comme paradigme de contrôle dans ce projet.

Boord et al. (2010) montrent que l'imagerie motrice du membre inférieur produit une désynchronisation alpha contralatérale spatialement discriminable, distinguant l'imagerie de la jambe gauche de la jambe droite avec des taux de classification de 72 à 83 % selon le côté ; l'imitation simultanée de séquences vidéo amplifiait cette désynchronisation, suggérant qu'un entraînement guidé par retour visuel pourrait accélérer l'apprentissage du contrôle BCI. Tariq et al. (2018) ont comparé plusieurs stratégies de classification pour distinguer l'imagerie de la marche d'un état de repos à partir des puissances alpha et bêta, confirmant la pertinence de ces bandes comme marqueurs du décodage locomoteur.

Alchalabi et al. (2019) montrent enfin que la sélection des canaux d'acquisition et la qualité du contact électrode-scalp influencent directement les performances de classification, un résultat particulièrement pertinent ici, où la comparaison entre électrodes humides et sèches interroge précisément l'impact de la qualité du signal sur ces performances.

2.3 Performances des méthodes de classification :

2.2.1 Méthodes de classification classiques :

Lotte et al. (2007) ont réalisé une revue systématique comparant plus d'une vingtaine de classifieurs sur des protocoles BCI standardisés. Sur des tâches d'imagerie motrice main gauche contre main droite, ils rapportent des précisions de l'ordre de 96,3 % pour la LDA standard dans des conditions favorables. La version régularisée (RLDA) améliore ces performances, atteignant 96,7 % contre 96,3 % pour la LDA non régularisée sur un premier jeu de données, et 93,7 % contre 90,7 % sur un second jeu plus difficile ; les auteurs recommandent de systématiquement régulariser les classifieurs pour faire face aux artefacts et à la variabilité inter-session. Les SVM, également étudiés, atteignent des performances comparables (96,8 % en version linéaire, 93,3 % en version gaussienne), au prix d'un temps d'entraînement plus élevé que la LDA.

Blankertz et al. (2008) illustrent l'efficacité du filtrage spatial CSP combiné à la LDA. Sur des données d'imagerie motrice main gauche contre main droite, le filtre CSP révèle un second pic spectral autour de 12 Hz à fort pouvoir discriminant, invisible sur le signal brut ou après un simple filtre Laplacien. Dans leurs études de feedback en temps réel sur six sujets sains, la combinaison CSP + LDA atteint une précision moyenne de 89,5 % en calibration et 90,5 % en feedback, avec un pic de transfert d'information de 35,4 bits/min pour le meilleur sujet.

2.2.2 Architectures d'apprentissage profond :

Roy et al. (2019), dans leur revue de 154 études sur l'apprentissage profond appliqué à l'EEG, rapportent que près de la moitié utilisent le signal brut ou minimalement prétraité comme entrée directe du réseau, confirmant la tendance vers un apprentissage de bout en bout. Sur les études comparant apprentissage profond et méthode traditionnelle, ils rapportent un gain médian de précision de 5,4 % (intervalle interquartile de 9,4 %), un gain modeste indiquant que l'apprentissage profond ne surpasse pas systématiquement les méthodes classiques, en particulier avec des données limitées. La majorité des études utilisent des réseaux de 3 à 10 couches, nettement plus superficiels qu'en vision par ordinateur, en raison du faible volume de données disponible en EEG.

Lawhern et al. (2018) ont évalué EEGNet sur quatre paradigmes BCI (P300, négativité liée à l'erreur, potentiel cortical lié au mouvement, rythme sensorimoteur). EEGNet égale ou surpasse les approches de référence spécifiques à chaque paradigme, notamment en classification intra-sujet sur les deux derniers. Les filtres spatiaux appris pour la bande 8-12 Hz présentent une forte corrélation avec ceux appris par FBCSP sur le même jeu de données, suggérant que le réseau extrait des représentations neurophysiologiquement interprétables.

Schirrneister et al. (2017) montrent que certains choix de conception sont déterminants pour DeepConvNet : la combinaison de la normalisation par lots, du dropout et des unités ELU s'est révélée indispensable pour atteindre un niveau compétitif face à FBCSP, sans quoi les performances chutaient significativement. Avec ces ajustements, DeepConvNet atteint une précision moyenne de 84,0 % contre 82,1 % pour FBCSP. Les auteurs montrent aussi qu'une stratégie d'entraînement par fenêtres glissantes améliore les performances en multipliant artificiellement le nombre d'exemples d'entraînement.

2.3 Synthèse et positionnement du projet :

Sur le plan clinique, neurophysiologique et technologique, cette revue de littérature met en évidence trois constats qui structurent la démarche de ce projet.

Sur le plan clinique, les BCI basées sur l'imagerie motrice ont démontré leur efficacité pour la réadaptation post-AVC, avec des gains cliniquement significatifs (Cervera et al., 2018). Alchalabi et al. (2021a) ont établi la faisabilité d'un système BCI multimodal pour le contrôle de la marche d'un avatar en réalité virtuelle, avec des performances satisfaisantes après quatre sessions. Ce système constitue le point de départ direct de ce projet, dont l'objectif est d'évaluer si ces résultats sont reproductibles avec un casque à électrodes sèches, plus adapté à un déploiement clinique routinier.

Sur le plan neurophysiologique, Malouin et al. (2003) et Boord et al. (2010) ont établi que l'imagerie motrice de la marche génère des modulations cérébrales réelles et discriminables, sous forme de désynchronisations ERD dans les bandes mu et bêta, justifiant son usage comme paradigme de contrôle.

Sur le plan technologique, la tension entre qualité de signal et praticabilité clinique reste un obstacle majeur au déploiement des BCI en routine hospitalière. Hinrichs et al. (2020) montrent que les électrodes sèches peuvent produire un signal comparable aux électrodes humides pour les

bandes de fréquence d'intérêt, sous réserve d'un prétraitement adapté. Aucune étude n'a toutefois évalué directement leur capacité à alimenter des algorithmes d'apprentissage profond comme EEGNet et DeepConvNet dans le contexte de l'imagerie motrice de la marche.

C'est ce dernier point que ce projet cherche à combler : en comparant RLDA, EEGNet et DeepConvNet sur des données acquises avec le casque Kaptics (électrodes sèches) et avec le casque de référence d'Alchalabi et al. (2021a) (électrodes humides), il vise à déterminer dans quelle mesure les électrodes sèches constituent une alternative pour les BCI de réadaptation de la marche.

CHAPITRE 3

MATÉRIEL ET ACQUISITION DES DONNÉES :

3.1 Protocole expérimental :

3.1.1 Participants et conditions d'acquisition :

Cette étude a été approuvée par le Comité d'éthique de la recherche de l'École de technologie supérieure (CER-ETS) le 15 avril 2026. L'ensemble des participants ont signé un formulaire d'information et de consentement avant toute participation.

Le protocole approuvé par l'éthique prévoyait le recrutement de douze participants adultes sains. Bien que les études de référence dans ce domaine aient typiquement recruté entre 15 et 20 participants (Alchalabi et al., 2021), cette étude adopte une approche exploratoire visant avant tout à évaluer la faisabilité de l'acquisition EEG avec un casque à électrodes sèches, plutôt qu'à atteindre une puissance statistique élevée. En raison de contraintes de temps et de difficultés techniques rencontrées avec le casque Kaptics en cours de projet, cinq participants ont finalement complété le protocole d'acquisition et disposent de données exploitables pour les analyses de classification présentées au Chapitre 5. Chaque participant réalisant environ 300 essais au total, répartis en 10 runs de 30 essais chacun, le volume de données EEG collectées par participant reste suffisant pour entraîner et évaluer les algorithmes de classification visés.

Les critères d'inclusion étaient les suivants : être âgés de 18 à 65 ans, être en bonne santé générale, comprendre le français écrit et oral, et avoir une vision normale ou corrigée à la normale. Étaient exclus les participants présentant des antécédents d'épilepsie, un trouble neurologique ou vestibulaire diagnostiqué, une médication susceptible d'affecter l'activité cérébrale ou des antécédents marqués de cyber malaise.

Chaque participant a été convié à une séance unique d'environ 90 minutes, réalisée au Laboratoire de capture de mouvement de l'ETS. La séance comprenait une phase d'installation et de vérification du signal EEG, la phase expérimentale proprement dite et un questionnaire oral post-expérimental pour évaluer le sentiment d'incarnation de l'avatar. Pour faciliter le contact des électrodes sèches avec le scalp, les participants étaient invités à se présenter avec les cheveux

propres et secs. Des pauses régulières entre les blocs expérimentaux permettaient de limiter la fatigue cognitive et de vérifier le maintien de la qualité du signal EEG.

3.1.2 Tâches d'imagerie motrices réalisées :

Le protocole expérimental de cette étude s'inspire directement de celui développé par Alchalabi et al. (2021), qui sert de référence méthodologique pour ce projet. Trois classes d'imagerie motrice ont été retenues, correspondant aux mouvements de base nécessaires pour contrôler la marche d'un avatar en réalité virtuelle : un pas avec le pied gauche, un pas avec le pied droit et une marche en continu. L'imagerie motrice des membres inférieurs produit des modulations mesurables dans les bandes mu (8-13 Hz) et bêta (13-30 Hz), principalement aux électrodes C3, Cz et C4, positionnées au-dessus des aires motrices associées aux jambes (section 1.2.2 ; Boord et al., 2010 ; Tariq et al., 2018).

La phase expérimentale comprenait 10 runs séparés par des pauses, pour un total de 300 essais. Chaque run comportait 30 essais (10 répétitions de chaque classe), présentés dans un ordre aléatoire différent à chaque run pour éviter tout effet d'anticipation.

Chaque essai suivait la séquence temporelle illustrée à la Figure 11 : une période de repos de 2 à 3 secondes établissait un signal EEG de référence, suivie de la présentation d'une flèche pendant environ 3 secondes. Dès sa disparition, le participant débutait la tâche d'imagerie motrice pendant 3 à 4 secondes, durée reprise d'Alchalabi et al. (2021). Une courte période de repos de 2 secondes séparait ensuite l'essai suivant.




Figure 11 : Séquence temporelle d'un essai d'imagerie motrice, illustrant les quatre phases : repos initial (2-3 s), présentation de la flèche directionnelle (~3 s), imagerie motrice avec déplacement de l'avatar (3-4 s) et repos inter-essai (~2 s).

Les participants avaient pour consigne d'imaginer le mouvement de la façon la plus réaliste possible, comme s'ils le réalisaient réellement, en gardant la tête et le corps immobiles pendant toute la durée de l'essai, et de ne commencer l'imagerie qu'après la disparition de la flèche.

3.1.3 Environnement de réalité virtuelle

L'environnement de réalité virtuelle a été développé à l'aide du moteur Unity 3D et présenté au participant par l'intermédiaire d'un casque de réalité virtuelle HTC Vive Focus Vision. Ce casque intègre également un système de suivi du regard, permettant d'enregistrer où le participant regarde dans l'environnement virtuel pendant les tâches d'imagerie motrice.

L'environnement virtuel consiste en un couloir infini dans lequel un avatar est présenté au participant depuis une perspective à la première personne. Le participant visualise ainsi les membres inférieurs de l'avatar comme s'il observait son propre corps en train de marcher (Figure 12). Ce choix de perspective repose sur des travaux montrant que la vue à la première personne favorise l'induction d'un sentiment d'incarnation du corps virtuel, et que ce sentiment est positivement corrélé aux performances de classification dans les BCI basées sur l'imagerie motrice (Alchalabi et al., 2021). L'environnement a été conçu de manière sobre, avec des textures simples, afin de limiter les sensations de mouvement illusoire pouvant être ressenties par le participant alors qu'il est physiquement immobile, ainsi que le risque de cybermalaise qui peut en résulter.



Figure 12 : Vue à la première personne de l'environnement virtuel, montrant les membres inférieurs de l'avatar tels que perçus par le participant.

Pour cette phase d'acquisition, les mouvements de l'avatar suivent un scénario prédéfini : c'est l'expérimentateur qui contrôle l'apparition des flèches et déclenche les mouvements correspondants de l'avatar, indépendamment de ce que le participant imagine. Cette approche permet de collecter des données EEG dans des conditions stables et reproductibles, qui serviront ensuite à entraîner et tester les algorithmes de classification. À terme, l'objectif est que l'activité cérébrale du participant pilote directement l'avatar en temps réel, sans intervention de l'expérimentateur.

3.2 Système à électrodes humides :

Les données de référence utilisées dans ce projet proviennent des travaux antérieurs menés au sein du laboratoire par Alchalabi et al. Acquisées avec un système EEG à électrodes humides dans le cadre de la même expérimentation d'imagerie motrice de la marche, elles servent de base pour développer et évaluer les algorithmes de classification, avant leur application aux données du casque à électrodes sèches.

3.2.1 Description du matériel :

Les signaux ont été enregistrés avec un système Smart BCI, un amplificateur sans fil portable équipé de 19 électrodes Ag/Cl selon le système 10-20 (Figure 13), avec l'électrode AFz utilisée comme masse et des clips auriculaires comme référence. Au-delà des électrodes centrales C3, Cz et C4 déjà décrites au Chapitre 1, ce montage inclut des électrodes supplémentaires ciblant des fonctions spécifiques à la marche : FCz, FC1 et FC2 pour la planification motrice, et CPz, CP1 et CP2 pour la navigation spatiale.

Les signaux étaient transmis sans fil via Bluetooth au logiciel EEGStudio, diffusés en temps réel via une API vers Matlab pour l'analyse et la classification en ligne, à une fréquence d'échantillonnage de 256 Hz.




Figure 13 : Les signaux EEG ont été enregistrés à l'aide d'un système Smart BCI, composé d'un bonnet EEG équipé de 19 électrodes Ag/Cl.

Le casque de réalité virtuelle utilisé, un Oculus Rift relié à un poste fixe, était positionné par-dessus le bonnet EEG (Figure 14) ; cette étape nécessitait une attention particulière, tout déplacement des électrodes pouvant dégrader le contact et introduire des artefacts. L'impédance était vérifiée après l'installation complète, avant le début de l'acquisition.



Figure 14 : Installation du casque de réalité virtuelle Oculus Rift par-dessus le bonnet EEG Smart BCI.

3.2.2 Caractéristiques du signal de référence :

Les données de référence ont été collectées auprès de 20 participants sains (12 femmes, 8 hommes), âgés en moyenne de $26,7 \pm 6,1$ ans, sur 4 sessions réparties sur 4 jours consécutifs. Chaque session durait environ 1h30, installation incluse. Les trois premières journées

comprenaient 10 runs de 30 essais (300 essais par session), la quatrième 10 runs de 15 essais (Alchalabi et al., 2021).

Les signaux ont été prétraités sous MATLAB avec la toolbox EEGLAB : filtrage passe-bande entre 8 et 30 Hz pour isoler les bandes mu et bêta, rejet automatique des artefacts par analyse en composantes indépendantes, et ligne de base établie sur les 200 ms précédant l'apparition de chaque flèche. Le détail complet du pipeline de prétraitement et des méthodes de classification appliqués à ces données est présenté au Chapitre 4 (Alchalabi et al., 2021).

Ce signal, acquis dans des conditions optimales grâce au contact stable assuré par le gel conducteur, constitue la référence de qualité de ce projet, servant de base de comparaison pour évaluer dans quelle mesure le casque à électrodes sèches produit un signal et des performances de classification équivalents.

3.3 Système à électrodes sèches :

3.3.1 Description du matériel :

Le système utilisé, le Kaptics Kit, comporte 16 électrodes sèches intégrées à l'attache arrière d'un casque de réalité virtuelle (Figure 15), remplaçant ainsi l'attache classique tout en permettant l'enregistrement EEG pendant l'immersion. Contrairement au système à électrodes humides, le contact électrode-peau est assuré mécaniquement par la pression du casque sur le cuir chevelu, sans gel conducteur, ce qui réduit significativement le temps de préparation.



Figure 15 : Composants du système Kaptics intégré au casque de réalité virtuelle, montrant les 16 électrodes sèches, le module de traitement et transmission, et le bras de maintien réglable.

La disposition des électrodes s'inspire du système 10-20, concentrée sur les régions centrales du scalp autour de C3, Cz et C4 (Figure 16), ciblant les rythmes sensorimoteurs associés à l'imagerie motrice des membres inférieurs. Le système comprend également des clips auriculaires comme référence et une électrode de masse. Les signaux sont transmis en temps réel à un ordinateur et enregistrés en fichiers CSV, avec les événements de l'expérience virtuelle enregistrés simultanément.




Figure 16 : Disposition des 16 électrodes du système Kaptics sur les régions centrales et centro-frontales du scalp, ciblant les rythmes sensorimoteurs associés à l'imagerie motrice des membres inférieurs.

Cette configuration présente toutefois des contraintes propres aux électrodes sèches : le contact est généralement moins stable et plus sensible aux mouvements que celui obtenu avec un gel conducteur, ce qui se traduit par une impédance plus élevée, un signal de plus faible amplitude et une sensibilité accrue au bruit. La qualité du signal dépend directement de la pression exercée par les électrodes, de la présence de cheveux, du positionnement précis des électrodes de référence et de masse, ainsi que des mouvements de tête du participant, ce qui exige une attention particulière lors de l'installation et tout au long de l'enregistrement.

3.3.2 Procédure d'installation et vérification du signal :

L'installation du casque EEG, réalisée avant chaque session, conditionne directement la qualité des données enregistrées. Le casque est positionné en veillant à son alignement avec les repères anatomiques du crâne, avec une attention particulière portée aux électrodes C3, Cz et C4, directement impliquées dans les tâches d'imagerie motrice. Plusieurs ajustements suivent pour optimiser le contact électrode-cuir chevelu : repositionnement local des électrodes, écartement des cheveux si nécessaire, et ajustement de la pression du casque. Les clips auriculaires de référence sont également vérifiés.

Avant le début du protocole, un script Python développé pour ce projet calcule en temps réel l'écart-type (STD) de chaque canal (Figure 17), l'indicateur principal de qualité du contact électrode-peau. Trois seuils qualifient chaque canal : bon au-dessus de $10\ \mu\text{V}$, moyen entre 5 et $10\ \mu\text{V}$, insuffisant en dessous de $5\ \mu\text{V}$; un STD supérieur à $200\ \mu\text{V}$ signale à l'inverse une anomalie sévère (artefact électronique ou mouvement brusque). Une attention particulière est portée aux canaux moteurs C3, C4 et Cz : un signal exploitable simultanément sur ces trois canaux est une condition nécessaire pour procéder à un run. Si ce n'est pas le cas, le casque est réajusté et la vérification est répétée jusqu'à obtention d'un signal satisfaisant.




Figure 17 : Exemple de sortie du script de monitoring en temps réel : écart-type par canal avec les seuils de qualité BON ($10\ \mu\text{V}$) et MOYEN ($5\ \mu\text{V}$).

Une période de préchauffage d'au moins 30 secondes est également respectée entre l'installation du casque et le début de chaque run, le temps que l'interface électrode-peau atteigne son équilibre électrochimique ; les essais survenant avant cette stabilisation sont exclus de l'analyse.

Une fois cette validation effectuée, le protocole expérimental (section 3.1.2) est lancé, avec des pauses entre les runs pour limiter la fatigue du participant. La qualité du signal peut être réévaluée en cours d'expérience, avec ajustement du casque si une dégradation est observée.

3.3.3 Analyse spectrale et identification des bandes EEG pertinentes :

En complément du STD, le script de monitoring produit deux indicateurs spectraux permettant d'évaluer si les données contiennent une information physiologique exploitable pour la classification. Le premier est la densité spectrale de puissance (PSD), calculée par la méthode de Welch pour les canaux C3, Cz et C4 (Figure 18), mettant en évidence les bandes mu (8-13 Hz) et bêta (13-30 Hz). La PSD permet de vérifier la présence de ces composantes d'intérêt et de détecter une dominance d'artefacts basse fréquence (sous 3 Hz), caractéristique des dérives lentes typiques des électrodes sèches.




Figure 18 : Densité spectrale de puissance (PSD) des canaux moteurs C3, Cz et C4, calculée par la méthode de Welch. Les bandes de fréquence Delta, Theta, Mu, Beta et Gamma sont indiquées par les zones colorées. Les bandes Mu (8-13 Hz) et Beta (13-30 Hz), encadrée en bleu et vert, sont les plus pertinentes pour l'imagerie motrice.

Le second indicateur est la désynchronisation liée à l'événement (ERD), calculée dans la bande mu pour chaque canal moteur et chaque classe d'imagerie (Figure 19), exprimée en pourcentage de variation par rapport à une période de repos. Une valeur négative indique une désynchronisation

pendant l'imagerie, signe d'une activité motrice détectable ; une valeur positive indique au contraire une synchronisation, pouvant signaler un artefact, un mauvais contact, ou une absence de modulation pour cette classe.




Figure 19 : Exemple de désynchronisation liée à l'événement (ERD) dans la bande mu (8-13 Hz) pour les canaux moteurs Cz, C3 et C4 d'un essai. Les zones colorées indiquent les bandes de fréquence (Thêta, Mu, Beta, Gamma). Une valeur négative traduit une désynchronisation (activité motrice détectable), une valeur positive une synchronisation. Les trois styles de trait correspondent aux trois classes d'imagerie motrice.

Un tableau de synthèse accompagne chaque figure de run (STD, classe de qualité et ERD par canal moteur), et une figure de synthèse multi-runs compare l'évolution de ces indicateurs au fil de la session, permettant d'identifier les runs exploitables et d'ajuster le protocole pour les sessions suivantes.

CHAPITRE 4 MÉTHODOLOGIE

4.1 Pipeline de prétraitement des signaux EEG :

Le prétraitement des signaux EEG constitue une étape fondamentale dans tout système BCI : il vise à supprimer les composantes non cérébrales susceptibles d'induire le classifieur en erreur, et à isoler les bandes de fréquence porteuses de l'information pertinente.

Deux pipelines distincts ont été utilisés dans ce projet (Figure 20). Pour les données Kaptics, un pipeline a été développé spécifiquement pour les propriétés de ce signal (impédance de contact plus élevée, amplitude réduite, dérives basse fréquence).




Figure 20 : Vue d'ensemble comparative des deux pipelines de prétraitement (Kaptics et humide).

Pour les données de référence à électrodes humides, l'accès au signal brut continu n'a pas été possible en raison d'un problème de stockage lors du transfert des données originales : les fichiers disponibles sont déjà segmentés (phases de repos et d'imagerie motrice), accompagnés de features spectrales précalculées (PSDAG) et conçus à l'origine pour une classification RLDA à 3 classes, sans catégorie IDLE explicite (Alchalabi et al., 2021). Le pipeline développé pour ce projet a donc dû s'adapter à ce format contraint : une architecture hiérarchique gate/expert a été conçue pour

reformuler le problème en 4 classes, et une stratégie de pondération par qualité de signal a compensé l'impossibilité d'un rejet d'artefacts classique sur un nombre de trials déjà limité.

4.1.1 Filtrage des signaux :

Pour les données Kaptics, le filtrage est appliqué sur le signal brut, avant segmentation en epochs, à l'aide de trois filtres appliqués séquentiellement sur les 16 canaux (Figure 21).

Un filtre passe-haut à 1 Hz (Butterworth d'ordre 4) élimine d'abord les dérives lentes du signal, particulièrement prononcées avec des électrodes sèches en raison d'un contact électrode-scalp moins stable qu'avec un gel conducteur ; non corrigées, ces dérives se superposeraient aux oscillations d'intérêt et dégraderaient l'extraction de features.

Un filtre coupe-bande (Notch) à 50 et 60 Hz supprime ensuite le bruit du réseau électrique, les deux fréquences étant filtrées simultanément pour couvrir les standards européen et nord-américain.

Enfin, un filtre passe-bande entre 8 et 30 Hz (Butterworth d'ordre 4) isole les bandes mu (8-13 Hz) et bêta (13-30 Hz), marqueurs neurophysiologiques principaux de l'imagerie motrice : la bande mu se désynchronise pendant la préparation et l'imagination du mouvement (ERD), tandis que la bande bêta présente un comportement complémentaire, avec une resynchronisation après le mouvement imaginé (rebond bêta post-mouvement) (Pfurtscheller et Lopes da Silva, 1999 ; Pfurtscheller et al., 1996). L'ensemble des filtres est appliqué via la fonction `filtfilt` de SciPy, qui évite tout décalage temporel du signal, essentiel pour l'alignement correct des epochs sur le protocole




Figure 21 Effet des quatre étapes de la chaîne de filtrage Kaptics sur un signal synthétique illustratif.

Pour les données de référence à électrodes humides, l'absence d'accès au signal brut (section 4.1) limite le filtrage au filtre IIR personnalisé A1013, précalculé et fourni avec les données originales, dont les coefficients sont restructurés en sections de second ordre (SOS) pour une application stable via `sosfiltfilt`. Ce nom fait référence à la bande 10-13 Hz (bande mu supérieure) : Alchalabi et al. (2021) avaient testé empiriquement plusieurs sous-bandes de 3 Hz sur l'ensemble de la plage 8-30 Hz pour chaque participant, et cette bande s'est révélée optimale pour la majorité d'entre eux. Ce filtre a été réutilisé tel quel, sans possibilité de le réoptimiser pour le sous-ensemble de sujets retenu ici, contrairement au pipeline Kaptics, conçu de bout en bout pour ce projet avec une bande large (8-30 Hz) laissant aux étapes suivantes le soin de faire émerger l'information discriminante.

4.1.2 Segmentation et épochage :

Une fois filtré, le signal est découpé en epochs, segments extraits autour d'un événement précis (Figure 22). Pour Kaptics, cet événement est l'apparition d'un marqueur Unity indiquant le début d'un essai. Pour les données humides, déjà segmentées par l'étude originale, la démarche diffère et est présentée en fin de section.




Figure 22 : Principe de la segmentation en epochs.

Le casque Kaptics enregistre le signal en fichiers CSV horodatés, indépendamment des marqueurs Unity horodatés séparément. Un script d'alignement recalcule les deux sources par correspondance des horodatages ; une erreur de quelques centaines de millisecondes suffirait à décaler la fenêtre d'imagerie par rapport à l'activité cérébrale réelle et à dégrader la classification.

Chaque essai comprend trois phases : repos, affichage d'une flèche pendant environ 2 secondes, puis imagerie motrice dès sa disparition, pendant environ 2,5 secondes (Figure 23). Le marqueur Unity est envoyé au moment de l'apparition de la flèche (confirmé par le code source, `GameManager.cs`, `arrowVisibleDurationSeconds = 2f`), donc $t=0$ correspond au début de la flèche, non au début de l'imagerie.




Figure 23 : Décomposition temporelle d'un essai d'imagerie motrice pour le système Kaptics.

Une analyse par fenêtre glissante de 1 seconde ($t=-0,5$ s à $t=+5,0$ s, pas de 0,2s), calculant l'accuracy RLDA à chaque position, a confirmé que le pic d'information discriminante se situe entre $t+2,0$ s et $t+4,5$ s (Figure 24), correspondant à la période d'imagerie motrice effective. Cette fenêtre a été retenue pour l'extraction des epochs, soit 2,5 secondes d'imagerie pure ; les résultats détaillés de cette analyse sont présentés au Chapitre 5. Une période de préchauffage de 30 secondes est également exclue en début de chaque run, en raison de la dérive du signal pendant la stabilisation électrochimique de l'interface électrode-peau.




Figure 24 : Représentation schématique illustrative de l'analyse par fenêtre glissante.

Pour les données humides, la situation diffère : les fichiers sont déjà segmentés en deux portions par essai, une fenêtre baseline (repos avant la flèche) et une fenêtre animation (imagerie et retour visuel) (Alchalabi et al., 2021). Aucun problème de synchronisation ne se pose donc ici, l'alignement ayant déjà été réalisé par l'étude originale, ni aucune analyse par fenêtre glissante, la fenêtre optimale ayant déjà été identifiée par segments de 200 ms sur la plage 4-8 s avec sélection par participant.

Pour EEGNet et DeepConvNet, l'entrée du réseau nécessite des sous-fenêtres de 256 échantillons, représentant soit un état de repos (nomove1, nomove2), soit une imagerie active (move1 à move4). Pour Kaptics, ces sous-fenêtres sont extraites directement du signal continu segmenté. Pour les données humides, ce découpage est imposé par le format des fichiers reçus, limités aux champs baseline et animation : le premier ne peut contenir que du repos, d'où nomove1/nomove2 ; le second que de l'imagerie, d'où move1 à move4.

Ces sous-fenêtres sont stockées séparément puis combinées selon des règles propres à chaque sous-modèle : pour le gate, nomove1 et nomove2 forment la classe IDLE tandis que move1 et move4 sont concaténées pour former la classe MOVE ; pour l'expert, seule move1 est utilisée, combinée à son équivalent filtré en bande bêta sur l'axe des canaux.

4.1.3 Rejet des artefacts :

Malgré le filtrage, certains epochs peuvent encore contenir des artefacts résiduels (mouvements brusques, contractions musculaires, contact électrode-peau instable), typiquement visibles sous forme de pics d'amplitude anormaux. Pour les données Kaptics, un critère de rejet par seuillage est appliqué automatiquement : tout epoch dont l'amplitude maximale dépasse $100 \mu\text{V}$ après filtrage est exclu, un seuil cohérent avec la littérature sur les systèmes BCI à électrodes sèches (Gu et al., 2021).

Pour les données humides, le rejet d'artefacts a déjà été effectué en amont par l'étude originale, via une analyse en composantes indépendantes (ICA) combinée à l'algorithme MARA (Alchalabi et al., 2021) ; les segments *baseline* et *animation* reçus sont donc déjà nettoyés. Un rejet supplémentaire par seuillage n'est pas envisageable ici, le faible nombre de trials par sujet et par jour ne permettant pas de réduire davantage l'ensemble de données. Une pondération par qualité de signal est appliquée à la place : pour chaque trial, la variance du signal est calculée sur l'ensemble des canaux et des points temporels ; un trial de variance inférieure à $1\text{e-}4 \mu\text{V}^2$, signe possible d'un mauvais contact résiduel non détecté par l'ICA/MARA, reçoit un poids réduit (0,2) dans la fonction de perte plutôt que d'être exclu, contre un poids de 1,0 pour les trials normaux. Cette approche conserve l'ensemble des données disponibles tout en limitant l'influence des trials les moins fiables.

4.1.4 Normalisation :

Deux opérations de normalisation sont appliquées séquentiellement sur chaque epoch après le rejet des artefacts (Figure 25).

La première est une soustraction de baseline : la moyenne du signal sur les 500 premières millisecondes de la fenêtre d'imagerie est retirée de l'ensemble de l'epoch, pour que les variations analysées reflètent des changements d'activité cérébrale par rapport au repos, plutôt que des différences de niveau absolu liées à la qualité variable du contact électrode-peau.

La seconde est une normalisation z-score, appliquée indépendamment par canal (soustraction de la moyenne, division par l'écart-type), pour standardiser la variabilité du signal quelle que soit l'amplitude initiale du canal. Cette étape est particulièrement importante avec les électrodes sèches, où la qualité de contact varie d'un canal à l'autre : sans elle, les canaux de forte

amplitude domineraient l'apprentissage du classifieur, indépendamment de leur contenu informatif réel.




Figure 25 : Effet de la normalisation z-score par canal (illustration schématique).

Pour les données humides, la situation diffère sur les deux opérations. La soustraction de baseline a déjà été effectuée par l'étude originale, qui retire un segment de référence de 200 ms précédant l'apparition de la flèche (Alchalabi et al., 2021) ; elle n'est donc pas reproduite ici. La normalisation z-score est en revanche appliquée, mais calculée une seule fois sur l'ensemble des données d'entraînement (moyenne et écart-type par canal), puis réutilisée telle quelle sur les données de test. Cette précaution anti-fuite (anti-leakage) évite que les données de test n'influencent indirectement la normalisation et l'apprentissage du modèle.

4.2 Méthodes de classification :

Trois algorithmes ont été évalués, représentant deux approches complémentaires : RLDA repose sur une extraction manuelle de features spectrales et spatiales, tandis qu'EEGNet et DeepConvNet apprennent automatiquement leurs représentations directement à partir du signal prétraité.

Les trois algorithmes ont été appliqués aux deux systèmes (Kaptics et humide), avec des implémentations adaptées aux contraintes de chaque pipeline. Pour Kaptics, les features sont calculées à partir du signal brut, et les architectures de deep learning traitent directement les epochs en 3 classes (Gauche, Droite, Marche). Pour les données humides, les features PSDAG sont

héritées du pipeline original, et les architectures de deep learning adoptent une structure hiérarchique gate/expert pour reformuler le problème en 4 classes (IDLE, RIGHT, LEFT, WALK), détaillée dans les sections suivantes. La validation repose sur le Leave-One-Run-Out (LORO), dont les modalités diffèrent également entre les deux systèmes (section 3.3).

4.2.1 RLDA — Analyse discriminante linéaire régularisée :

Les principes théoriques du RLDA et du filtrage CSP associé ont été présentés au Chapitre 1 (section 1.5.1). Cette section détaille uniquement les choix d'implémentation propres à chaque pipeline.




Figure 26 : Pipeline d'extraction de features et de classification RLDA (données Kaptics)

Pour Kaptics, le classifieur travaille sur un vecteur combinant des features spectrales et spatiales (Figure 26). Les features spectrales sont calculées par la méthode de Welch, plus robuste qu'une simple FFT, et intégrées sur quatre bandes d'intérêt : mu (8-13 Hz), bêta basse (13-20 Hz), bêta haute (20-30 Hz) et bêta large (13-30 Hz), pour chacun des 16 canaux (Figure 27). S'y ajoutent des ratios asymétriques C3/C4 par bande, quantifiant la latéralisation entre hémisphères, et des ratios

mu/bêta par canal, capturant le couplage temporel entre bandes selon la phase du mouvement imaginé.




Figure 27 : Bandes de fréquence utilisées pour l'extraction de features PSD (données Kaptics, signal synthétique illustratif).

Les features spatiales sont obtenues par CSP en mode One-vs-Rest, un ensemble de filtres indépendant étant calculé pour chaque classe contre les deux autres. Les composantes retenues sont exprimées en log-variance du signal projeté (section 1.5.1). Le nombre de composantes a été fixé à 12 après optimisation, un compromis entre capture insuffisante de l'information spatiale et risque de surapprentissage lié à un nombre de features trop élevé par rapport aux epochs disponible.

L'ensemble des features est concaténé en un vecteur par epoch, entrée du classifieur. La régularisation est estimée automatiquement par la méthode de Ledoit-Wolf (shrinkage="auto"), adaptée à un nombre d'exemples variable d'un run à l'autre. Les trois classes cibles sont Gauche, Droite et Marche.

Pour les données humides, le pipeline diffère structurellement, les features étant reconstruites depuis les segments déjà fournis par l'étude originale plutôt que calculées sur signal brut. Les features PSDAG (645 dimensions) suivent la logique d'Alchalabi et al. (2021) : pour chaque trial, la fenêtre move1 (256 échantillons, première seconde d'imagerie) est extraite du segment

animation après filtrage A1013 (bande 10-13 Hz), puis la PSD et les ratios asymétriques sont calculés par canal, de façon analogue au pipeline Kaptics mais restreinte à cette seule bande.

Une quatrième classe, IDLE, est introduite par rapport au pipeline original (limité à trois classes motrices), construite à partir des fenêtres *nomove1* et *nomove2* extraites du segment *baseline*, sur lesquelles les mêmes features PSDAG sont calculées.

La régularisation est ici fixée à une valeur constante ($\text{shrinkage}=0,4$), héritée du pipeline original, pour garantir une cohérence entre les différentes configurations de jours testées sans réoptimisation à chaque fois. La validation repose sur une validation croisée à 10 folds stratifiés (StratifiedKFold) plutôt que sur LORO, le nombre de trials par run étant trop faible pour exclure un run entier sans dégrader excessivement l'ensemble d'entraînement. Les quatre classes cibles sont IDLE, RIGHT, LEFT et WALK.

4.2.2 EEGNet — Architecture et paramétrage :

EEGNet est un réseau convolutif compact développé pour l'EEG par Lawhern et al. (2018), qui apprend directement ses représentations à partir du signal brut, sans extraction manuelle de features. L'architecture comprend deux blocs : le premier applique une convolution temporelle (apprentissage de filtres de fréquence) puis une convolution spatiale depthwise sur les 16 canaux, conceptuellement similaire au CSP mais entièrement apprise ; le second applique une convolution séparable captant les patterns temporels de haut niveau. Un classifieur linéaire final produit les prédictions.

Une recherche d'hyperparamètres a été menée pour adapter le réseau au faible volume de données et à la variabilité de signal propres à ce projet, deux facteurs qui s'écartent des conditions de la publication originale. Ont été testés : le nombre de filtres temporels F1 (4, 8, 16), le taux de dropout (0,25 et 0,5, la publication originale recommandant 0,5, potentiellement trop agressif sur un petit dataset), le taux d'apprentissage (1×10^{-3} , 5×10^{-4} , 1×10^{-4}), et trois plages de filtrage en entrée (bande large 8-30 Hz, mu seule 8-13 Hz, bêta seule 13-30 Hz), pour évaluer si le réseau bénéficie d'un signal large ou d'une bande restreinte concentrant l'information pertinente. Chaque configuration a été évaluée par LORO sur un sujet de référence ; les résultats détaillés, incluant les courbes d'entraînement, sont présentés au Chapitre 5.

La configuration retenue est : F1=8, D=2, F2=16, kernel_gate=128 échantillons (~500 ms), kernel_expert=192 échantillons (~750 ms), dropout=0,25, taux d'apprentissage 5×10^{-4} avec scheduler ReduceLROnPlateau, bande bêta (13-30 Hz), et patience d'early stopping de 40 epochs.

Pour compenser le faible volume de données, une augmentation a été appliquée uniquement sur les données d'entraînement de chaque fold, jamais sur le test. Deux techniques sont combinées : bruit gaussien léger ($\sigma=0,05$, 3 copies), simulant la variabilité naturelle du signal, et décalage temporel aléatoire (± 25 échantillons, 2 copies), simulant les variations de timing entre marqueur et réponse cérébrale. Chaque epoch génère ainsi 6 copies augmentées, portant le volume d'entraînement de 233 à environ 1400 epochs par fold.

4.2.3 DeepConvNet — Architecture et paramétrage :

DeepConvNet, développé par Schirrneister et al. (2017), est une architecture convolutive plus profonde qu'EEGNet, apprenant elle aussi directement ses représentations à partir du signal brut, au prix d'un nombre de paramètres plus élevé. L'architecture comprend quatre blocs : le premier, analogue à celui d'EEGNet, combine convolution temporelle et spatiale pour extraire des features de bas niveau ; les trois suivants appliquent chacun une convolution temporelle réduite, une normalisation par batch, une activation ELU, un MaxPooling et un dropout, avec un nombre de filtres croissant (25, 50, 100, 200). Un classifieur linéaire final produit les prédictions.

La principale différence avec EEGNet réside dans la profondeur et l'usage du MaxPooling plutôt que l'AveragePooling, potentiellement avantageux pour détecter des événements transitoires, mais au prix d'une sensibilité accrue au surapprentissage sur un dataset limité.

La même démarche de recherche d'hyperparamètres qu'EEGNet a été appliquée, d'autant plus importante ici que la plus grande capacité du réseau le rend plus sensible aux choix de régularisation. Ont été testés : le dropout (0,25 et 0,5, une régularisation plus forte étant attendue nécessaire compte tenu de la profondeur du réseau), le taux d'apprentissage (1×10^{-3} et 5×10^{-4}), et les mêmes trois plages de fréquence qu'EEGNet (8-30 Hz, mu seule, bêta seule), pour comparer si les deux architectures convergent vers la même bande optimale. Chaque configuration a été évaluée par LORO sur un sujet de référence ; les résultats détaillés sont présentés au Chapitre 5.

La configuration retenue est : trois blocs convolutifs (25, 50, 100 filtres), dropout=0,5, taux d'apprentissage 1×10^{-3} avec scheduler ReduceLROnPlateau, bande large 8-30 Hz, et patience d'early stopping de 30 epochs. La même stratégie d'augmentation qu'EEGNet a été appliquée pour garantir une comparaison équitable entre les deux architectures : bruit gaussien ($\sigma=0,05$, 3 copies) et décalage temporel (± 25 échantillons, 2 copies), pour un facteur $\times 6$ par epoch d'entraînement.

Tableau 3 : Comparaison des hyperparamètres utilisés pour l'entraînement des architectures EEGNet et DeepConvNet.

Hyperparamètre	EEGNet	DeepConvNet
Blocs convolutifs	2	3
Filtres	F1 = 8, D = 2, F2 = 16	25 $\rightarrow$ 50 $\rightarrow$ 100
Kernel temporel	gate = 128, expert = 192	1 $\times$ 64
Pooling	AveragePool	MaxPool
Dropout	0,25	0,5
Taux d'apprentissage	5×10^{-4}	1×10^{-3}
Bande de fréquence	13–30 Hz (bêta)	8–30 Hz (large)
Patience early stopping	40 epochs	30 epochs
Taille de batch	64	64
Augmentation	$\times 9$	$\times 3$

4.3 Procédure d'entraînement et validation :

4.3.1 Stratégie de validation croisée :

La stratégie adoptée pour l'ensemble des algorithmes est le Leave-One-Run-Out (LORO, Figure 28) : le classifieur est entraîné sur 9 runs et testé sur le run restant, l'opération étant répétée 10 fois pour que chaque run serve exactement une fois de test. L'accuracy finale agrège les prédictions des 10 folds.




Figure 28 : Schéma de la stratégie de validation croisée Leave-One-Run-Out (LORO) utilisée pour l'évaluation des modèles. À chaque itération, un run est réservé au test tandis que les neuf autres sont utilisés pour l'entraînement ; la performance finale correspond à la moyenne des 10.

Cette stratégie garantit une séparation temporelle stricte entre entraînement et test, essentielle pour des signaux EEG marqués par une forte non-stationnarité : leurs propriétés varient d'un run à l'autre, en raison de la fatigue du participant, de l'évolution du contact des électrodes sèches et de la variabilité naturelle de l'activité cérébrale. Tester sur un run entier garantit ainsi que les performances mesurées reflètent une vraie capacité de généralisation, plutôt qu'une mémorisation de patterns propres à une courte fenêtre. Cette stratégie est aussi identique à celle d'Alchalabi et al. (2021), ce qui facilite la comparaison entre les deux systèmes d'acquisition.

Pour EEGNet et DeepConvNet, l'augmentation de données est appliquée uniquement sur les données d'entraînement de chaque fold, jamais sur le test, afin d'éviter un gonflement artificiel des performances, les epochs augmentés étant statistiquement proches des originaux.

Des courbes d'entraînement et de validation sont enregistrées pour chaque fold, ainsi que l'epoch d'early stopping, afin de diagnostiquer la convergence des modèles, détecter d'éventuels cas de surapprentissage, et comparer le comportement d'EEGNet et de DeepConvNet en lien avec leur différence de complexité.

4.3.2 Métriques d'évaluation :

La métrique principale est l'accuracy globale, soit le rapport entre prédictions correctes et prédictions totales. Pour un problème à trois classes équilibrées, le niveau de chance théorique est de 33,3 % ; toute performance significativement supérieure indique une information discriminante réellement apprise par le classifieur.

L'accuracy par classe est également reportée pour chaque algorithme et chaque fold, afin d'identifier d'éventuels déséquilibres entre classes ou une stratégie dégénérée de prédiction systématique de la classe majoritaire. Le rapport de classification complet, incluant précision, rappel et F1-score par classe (Figure 29), est aussi calculé : la précision mesure la proportion de prédictions correctes parmi les essais assignés à une classe, le rappel la proportion d'essais correctement identifiés parmi ceux réellement de cette classe, et le F1-score, moyenne harmonique des deux, offre une mesure équilibrée tenant compte des faux positifs et des faux négatifs.




Figure 29 : Représentation schématique des métriques de classification précision, rappel et score F1, ainsi que de leurs relations avec les vrais positifs, faux positifs et faux négatifs.

Les courbes d'entraînement et de validation, ainsi que les epochs d'early stopping, sont présentées pour la configuration retenue sur plusieurs sujets représentatifs, afin d'évaluer la stabilité de l'entraînement et de comparer le comportement d'EEGNet et de DeepConvNet en lien avec leur différence de complexité.

CHAPITRE 5 RÉSULTATS

5.1 Résultats sur les données à électrodes humides (référence) :

Cette section présente les performances des trois classifieurs RLDA, EEGNet et DeepConvNet obtenus sur les données EEG acquises avec le système à électrodes humides Smart BCI (Mitsar), qui constituent les données de référence de ce projet. Ces résultats servent de point de comparaison pour l'évaluation ultérieure des mêmes algorithmes sur les données issues du casque à électrodes sèches Kaptics.

5.1.1 Performances de RLDA :

Les performances du classifieur RLDA ont été évaluées sur les données à électrodes humides issues des travaux d'Alchalabi et al., sur 13 sujets, selon sept configurations d'entraînement correspondant aux différentes combinaisons de jours disponibles. La validation repose sur une validation croisée à 10 plis stratifiée. Les résultats obtenus sont présentés dans le tableau suivant.

Tableau 4 : Performances moyennes RLDA selon les configurations d'entraînement.

Configuration	Précision moyenne (%)
Jour 1	78,8
Jour 2	79,3
Jour 3	79,6
Jours 1+2	79,1
Jours 1+3	79,1
Jours 2+3	80,0
Jours 1+2+3	79,2

Les performances sont remarquablement stables à travers toutes les configurations, oscillant entre 78.8 % pour le Jour 1 seul et 80.0 % pour la configuration Jours 2+3. Contrairement à ce qu'on pourrait attendre, l'accumulation des sessions n'améliore pas de façon monotone les performances : la configuration Jours 2+3 donne les meilleurs résultats (80.0 %) tandis que la fusion complète Jours 1+2+3 donne 79.2 %, légèrement en dessous. Cette stabilité s'explique en partie par la nature

des features PSDAG utilisées, qui capturent des représentations spectrales compactes et robustes aux variations inter-session.

La variabilité inter-sujet reste notable : Subj19 obtient des performances nettement inférieures à la moyenne (70,8 %) quelle que soit la configuration, tandis que Subj04, Subj08 et Subj12 dépassent systématiquement 80 %. Les résultats détaillés par sujet et par configuration figurent à l'Annexe II (Tableau-A II 1).

Ces chiffres restent sous les $86,0 \pm 6,1$ % rapportés par Alchalabi et al. (2021). Trois raisons probables : pas de débruitage ICA+MARA ici, un filtre fixe à 10-13 Hz au lieu d'un filtre ajusté par sujet, et une fenêtre temporelle fixe plutôt que choisie parmi plusieurs options. Ces résultats servent de point de comparaison pour les réseaux profonds vus dans les sections qui suivent.

5.1.2 Performances de EEGNet :

Avant de présenter les résultats finaux, une recherche systématique des hyperparamètres a été conduite afin d'identifier la configuration optimale pour ce dataset. Les résultats de cette recherche, évaluée par LORO partiel sur trois sujets de référence (Subj04, Subj05, Subj07), sont présentés dans le tableau suivant.

Tableau 5 : Résultats de la recherche d'hyperparamètres EEGnet.

Configuration	BalAcc moyenne (%)	Acc moyenne (%)
band-beta (13-30 Hz)	55.0 %	70.0 %
base (8-30 Hz, F1=8, do=0.25, lr= 5×10^{-4})	52.5 %	68.3 %
lr = 1×10^{-4}	52.5 %	68.3 %
dropout = 0.5	51.7 %	67.8 %
F1 = 4	50.8 %	67.2 %
kernel_gate = 64	50.0 %	66.7 %
F1 = 16	50.0 %	66.7 %
band-mu (8-13 Hz)	46.7 %	64.4 %
lr = 1×10^{-3}	45.8 %	63.9 %
kernel_expert = 128	44.2 %	62.8 %

La bande bêta seule (13-30 Hz) s'est révélée la plus performante, avec une balanced accuracy moyenne de 55,0 % sur les trois sujets, suggérant que la désynchronisation bêta pendant l'imagerie et le rebond post-mouvement portent le signal le plus discriminant pour ce pipeline gate+expert.

À l'inverse, $\text{kernel_expert}=128$ et $\text{lr}=1 \times 10^{-3}$ donnent les performances les plus faibles, confirmant que l'expert a besoin d'un filtre temporel long et d'un taux d'apprentissage modéré pour bien converger.

Les performances d'EEGNet ont ensuite été évaluées sur l'ensemble des sujets disponibles selon les différentes configurations de sessions. Les résultats obtenus sur 9 sujets sont présentés dans le tableau suivant :

Tableau 6 : Performances moyennes EEGNet selon les configurations d'entraînement.

Configuration	Précision moyenne (%)
Jour 1	68,3
Jour 2	66,8
Jour 3	67,2
Jours 1+2	71,8
Jours 1+3	73,6
Jours 2+3	73,0

Les configurations mono-session restent homogènes (66,8 % à 68,3 %). La fusion de plusieurs jours améliore systématiquement les performances, avec un gain jusqu'à 5,3 points pour Jours 1+3 (73,6 %) par rapport au Jour 1 seul, suivie de près par Jours 2+3 (73,0 %). L'accumulation inter-session profite donc à EEGNet, probablement en enrichissant la diversité des exemples et en aidant le réseau à mieux gérer la variabilité inter-session propre à l'EEG.

La variabilité inter-sujet reste modérée : Subj08 et Subj12 atteignent 75,0 % et 75,8 % en Jours 1+3, tandis que Subj07 plafonne à 65,0 % en Jour 1. Le détail par sujet et par configuration figure à l'Annexe II.

5.1.3 Performances de DeepConvNet :

Avant de présenter les résultats finaux, une recherche systématique des hyperparamètres a été conduite afin d'identifier la configuration optimale pour ce dataset. Les résultats de cette recherche, évaluée par LORO partiel sur trois sujets de référence (Subj04, Subj05, Subj07), sont présentés dans le tableau suivant.

Tableau 7 : Résultats de la recherche d'hyperparamètres DeepConvNet.

Configuration	BalAcc moyenne (%)	Acc moyenne (%)
$lr = 1 \times 10^{-3}$	54.5 %	68.4 %
base (dropout=0.5, $lr=5 \times 10^{-4}$, 8-30Hz)	53.1 %	67.8 %
dropout = 0.25	51.7 %	66.9 %
band-mu (8-13 Hz)	49.8 %	65.7 %
$lr = 1 \times 10^{-4}$	47.2 %	64.1 %
band-beta (13-30 Hz)	39.1 %	59.3 %

* Recherche réalisée sur 3 sujets (Subj04, Subj05, Subj07), Jour 1, LORO partiel (folds 1 et 5), 60 epochs, patience 15.

Contrairement à EEGNet, où la bande bêta s'était révélée optimale, c'est le taux d'apprentissage $lr=1 \times 10^{-3}$ qui donne la meilleure configuration pour DeepConvNet, avec une balanced accuracy de 54,5 % et une accuracy de 68,4 % sur les trois sujets de référence. La bande bêta seule (13-30 Hz) donne au contraire les moins bons résultats (39,1 % / 59,3 %), ce qui suggère que DeepConvNet a besoin d'un signal large bande pour exploiter sa capacité d'apprentissage, contrairement à EEGNet qui tire parti d'un signal plus ciblé. La configuration retenue est dropout=0,5, $lr=1 \times 10^{-3}$, bande 8-30 Hz.

Les performances de DeepConvNet ont ensuite été évaluées sur l'ensemble des sujets disponibles selon les différentes configurations de sessions. Les résultats obtenus sur 9 sujets sont présentés dans le tableau suivant.

Tableau 8 : Performances moyennes DeepConvNet selon les configurations d'entraînement.

Configuration	Précision moyenne (%)
Jour 1	68,4
Jour 2	67,9
Jour 3	67,0
Jours 1+2	71,1
Jours 1+3	72,2
Jours 2+3	70,5

Sur les configurations mono-session, DeepConvNet reste stable autour de 68 %. La fusion des sessions améliore les performances, la meilleure étant Jours 1+3 (72,2 %), suivie de Jours 1+2

(71,1 %), cohérent avec l'idée que DeepConvNet bénéficie d'un volume de données plus important pour converger, tant que la variabilité inter-session reste gérable.

En configuration mono-session, DeepConvNet (68,4 % en Jour 1) et EEGNet (68,3 %) atteignent un niveau très proche. Leurs comportements se rapprochent encore davantage en configuration multisession, les deux architectures bénéficiant de la fusion des jours. Le détail par sujet et par configuration figure à l'Annexe II.

5.2 Résultats sur les données à électrodes sèches (Kaptics) :

5.2.1 Performances de RLDA :

Le classifieur RLDA a été évalué sur les données acquises avec le système Kaptics selon la stratégie de validation Leave-One-Run-Out (LORO), pour les 5 sujets ayant complété l'acquisition, à raison de 10 runs chacun. Le pipeline complet : extraction des caractéristiques spectrales (PSD par bande de fréquence), ratios d'asymétrie C3/C4, filtres CSP (Common Spatial Patterns) et sélection des caractéristiques les plus discriminantes, a été appliqué à chacun des sujets selon une procédure identique. Les résultats sont présentés au tableau suivant.

Les hyperparamètres du pipeline (nombre de composantes CSP, nombre de caractéristiques retenues après sélection) ont été déterminés par exploration empirique plutôt que par une recherche d'hyperparamètres formelle sur un jeu de validation indépendant. La configuration retenue (12 composantes CSP, 25 caractéristiques sélectionnées) est celle ayant produit les meilleurs résultats lors de cette exploration. Cette approche, bien qu'utile pour évaluer le potentiel du pipeline, introduit un léger biais optimiste par rapport à une évaluation strictement indépendante des hyperparamètres et des données de test.

Tableau 9 : Accuracy globale RLDA par sujet.

Sujet	Accuracy globale	Au-dessus du hasard
Sujet 01	60.4%	+27.0%
Sujet 02	61.1%	+27.7%
Sujet 03	56.1%	+22.7%
Sujet 04	65.0%	+31.7%
Sujet 05	57.9%	+24.5%

L'ensemble des cinq sujets présente une accuracy nettement supérieure au niveau de chance, avec une variabilité inter-sujets relativement restreinte (écart-type de 3.2 points, valeurs comprises entre 56.1% et 65.0%). Cette cohérence entre sujets indique que le classifieur parvient à extraire une information discriminante stable à partir des caractéristiques spectrales et spatiales du signal EEG, malgré la variabilité individuelle propre à chaque sujet.

La Figure suivante présente les résultats détaillés obtenus pour le Sujet 01, incluant la matrice de confusion globale, l'accuracy par run et par classe, ainsi que les matrices de confusion des trois runs les plus performants (run7 : 75.0%, run10 : 71.4%, run4 : 67.9%). L'ensemble des figures similaires pour les quatre autres sujets est présenté à l'Annexe IV.




Figure 30 : Résultats de classification RLDA pour le Sujet 01.

5.2.2 Performances de EEGNet :

Le classifieur EEGNet a été évalué sur les données acquises avec le système Kaptics selon la stratégie de validation Leave-One-Run-Out (LORO), pour les 5 sujets ayant complété l'acquisition, à raison de 10 runs chacun. L'architecture gate+expert a été appliquée à chacun des sujets selon une procédure identique. Les résultats sont présentés au tableau suivant.

Les hyperparamètres du modèle (bande de fréquence, longueur du filtre temporel de l'expert, taux d'apprentissage) n'ont pas fait l'objet d'une recherche dédiée aux données Kaptics. La configuration retenue est celle déjà identifiée comme optimale lors de la recherche menée sur les données à électrodes humides. Cette approche, motivée par des contraintes de temps, introduit une limite méthodologique : la configuration utilisée n'est pas nécessairement adaptée aux caractéristiques spectrales propres aux données Kaptics, et les performances rapportées doivent être interprétées en tenant compte de cette réserve.

Tableau 10 : Accuracy globale EEGNet sur cinq jeux de données EEG.

Sujet	Accuracy globale (%)	Écart au hasard (33,3 %)
Sujet 01	60,0	+26,7 %
Sujet 02	60,7	+27,4 %
Sujet 03	72,1	+38,8 %
Sujet 04	66,8	+33,5 %
Sujet 05	33,6	+0,2 %
Moyenne (n = 5)	58,6	+25,3 %

Contrairement à RLDA, dont la performance restait relativement homogène entre sujets (écart-type de 3.2 points), EEGNet présente une variabilité inter-sujets nettement plus marquée, allant de 33.6% (Sujet 05, quasiment au niveau du hasard) à 72.1% (Sujet 03). Cet écart-type d'environ 15 points, près de cinq fois supérieur à celui observé pour RLDA, illustre la sensibilité plus grande des architectures d'apprentissage profond à la variabilité stochastique du signal et de l'initialisation du réseau, particulièrement dans un contexte de volume de données restreint (252 epochs d'entraînement par fold, avant augmentation).

La Figure suivante présente les résultats détaillés obtenus pour le Sujet 01 (accuracy globale de 60.0%), incluant la matrice de confusion globale, l'accuracy par run et les matrices de confusion des trois runs les plus performants (run7 : 82.1%, run9 : 67.9%, run4 : 64.3%). La matrice de confusion globale montre une diagonale dominante (49, 58 et 61 prédictions correctes pour Gauche, Droite et Marche respectivement), cohérente avec l'accuracy moyenne obtenue.




Figure 31 : Résultats de classification EEGNet (Sujet 01)

5.2.3 Performances de DeepConvNet :

Le classifieur DeepConvNet a été évalué sur les données acquises avec le système Kaptics selon la stratégie de validation Leave-One-Run-Out (LORO), pour les 5 sujets ayant complété l'acquisition, à raison de 10 runs chacun. L'architecture, comportant quatre blocs convolutifs (25→50→100→200 filtres), a été appliquée à chacun des sujets selon une procédure identique. Les résultats sont présentés au tableau suivant.

Comme pour EEGNet, les hyperparamètres du modèle (nombre de filtres par bloc, taux de dropout, taux d'apprentissage) n'ont pas fait l'objet d'une recherche dédiée aux données Kaptics. La configuration retenue est celle déjà identifiée comme optimale lors de la recherche menée sur les données à électrodes humides. Cette limite méthodologique, motivée par des contraintes de temps, doit être prise en compte dans l'interprétation des résultats rapportés.

Tableau 11 : Accuracy globale DeepConvNet par sujet (validation LORO, données Kaptics).

Sujet	Accuracy globale (%)	Écart au hasard (33,3 %)
Sujet 01	54,2	+20,9 %
Sujet 02	57,1	+23,8 %
Sujet 03	61,4	+28,1 %
Sujet 04	58,6	+25,3 %
Sujet 05	52,8	+19,5 %
Moyenne (n = 5)	56,8	+23,5 %

Contrairement à EEGNet, dont la variabilité inter-sujets était marquée (écart-type de 15,1 points), DeepConvNet présente une stabilité comparable à celle de RLDA, avec un écart-type d'environ 3,1 points et des performances individuelles comprises entre 52,8 % et 61,4 %. Cette homogénéité est notable dans la mesure où DeepConvNet, de par sa profondeur architecturale et son nombre de paramètres nettement supérieur à celui d'EEGNet, serait a priori davantage exposé à la variabilité stochastique de l'initialisation et du volume de données restreint. La stabilité observée ici suggère que le taux de dropout élevé (0,5) et la régularisation associée limitent efficacement cette sensibilité, au prix toutefois d'une accuracy moyenne légèrement inférieure à celle de RLDA et d'EEGNet (56,8 % contre 60,1 % et 58,6 % respectivement).




Figure 32 : Résultats de classification DeepConvNet (Sujet 01)

5.3 Comparaison globale des performances :

5.3.1 Comparaison inter-classifieurs (RLDA vs EEGNet vs DeepConvNet) :

Cette section compare directement les trois classifieurs, d'abord sur les données à électrodes humides, puis sur les données Kaptics.

- **Données à électrodes humides :**

Tableau 12 : Précision des modèles RLDA, EEGNet et DeepConvNet pour différentes configurations de données sur les électrodes humides.

Configuration	RLDA	EEGNet	DeepConvNet
Jour 1	78,8 %	68,3 %	68,4 %
Jour 2	79,3 %	66,8 %	67,9 %
Jour 3	79,6 %	67,2 %	67,0 %
Jours 1+2	79,1 %	71,8 %	71,1 %
Jours 1+3	79,1 %	73,6 %	72,2 %
Jours 2+3	80,0 %	73,0 %	70,5 %
Moyenne	79,3 %	70,1 %	69,5 %

La première observation est que RLDA surpasse les deux architectures profondes dans toutes les configurations (79,3 % en moyenne, contre 70,1 % pour EEGNet et 69,5 % pour DeepConvNet), un écart en partie attribuable au biais structurel des données, prétraitées et optimisées pour ce pipeline (section 6.1.1).

La deuxième observation concerne le comportement des trois classifieurs face à l'accumulation de données inter-session. RLDA reste très stable (78,8 % à 80,0 %). EEGNet gagne jusqu'à 5,3 points entre Jour 1 seul (68,3 %) et Jours 1+3 (73,6 %). DeepConvNet suit une trajectoire similaire, avec un gain plus modeste de 3,8 points (68,4 % à 72,2 %), sa complexité architecturale nécessitant davantage de données pour exploiter pleinement la diversité inter-session, contrairement à EEGNet qui tire parti plus efficacement de chaque exemple supplémentaire.

En mono-session, EEGNet et DeepConvNet atteignent un niveau presque identique (68,3 % et 68,4 % au Jour 1) ; c'est surtout en multisession que leurs comportements divergent, EEGNet bénéficiant davantage de l'accumulation des données.

Les courbes d'entraînement pour Subj05 en configuration Jour 1 (Figures 33 et 34) illustrent cette différence de comportement ; celles de Subj08 et Subj12 figurent à l'Annexe II.




Figure 33 : Courbes d'entraînement et de validation EEGNet pour Subj05, configuration Jour 1. Gate (gauche) : convergence à l'epoch 102. Expert (droite) : surapprentissage visible entre les courbes d'entraînement et de validation sur la tâche à trois classes.




Figure 34 : Courbes d'entraînement et de validation DeepConvNet pour Subj05, configuration Jour 1. Gate (gauche) : convergence rapide à l'epoch 37. Expert (droite) : convergence à l'epoch 83 avec courbes train/val proches, indiquant une bonne généralisation.

- **Données à électrodes sèches (Kaptics) :**

Classifieur	Accuracy moyenne (%)	Écart-type inter-sujets (points)	Écart au hasard (33,3 %)
RLDA	60,1	3,2	+26,8 %
EEGNet	58,6	15,1	+25,3 %
DeepConvNet	56,8	3,1	+23,5 %

Contrairement à la comparaison sur données humides, où RLDA surpassait nettement les deux architectures d'apprentissage profond (écart de 9,2 points avec EEGNet), les trois classifieurs obtiennent ici des performances moyennes relativement proches sur les données Kaptics, comprises entre 56,8 % et 60,1 %. Ce rapprochement s'explique en partie par la nature différente des deux jeux de données : les données Kaptics, contrairement aux données humides prétraitées spécifiquement pour le pipeline RLDA, ne présentent pas le même biais structurel en faveur de cette méthode, ce qui réduit l'avantage habituellement observé pour les approches à extraction explicite de caractéristiques.

La différence la plus marquante entre les trois classifieurs réside toutefois dans leur stabilité inter-sujets. RLDA et DeepConvNet présentent tous deux une variabilité restreinte et comparable (écart-type de 3,2 et 3,1 points respectivement), avec des performances individuelles comprises entre 56,1 % et 65,0 % pour RLDA, et entre 52,8 % et 61,4 % pour DeepConvNet. EEGNet, à l'inverse, montre une variabilité près de cinq fois supérieure (écart-type de 15,1 points), allant d'une performance quasi nulle au-dessus du hasard pour un sujet (33,6 %) à une performance nettement supérieure pour un autre (72,1 %). Cette stabilité comparable de RLDA et DeepConvNet, malgré leur différence fondamentale d'approche (extraction explicite de caractéristiques contre apprentissage profond de bout en bout), suggère que le taux de dropout élevé de DeepConvNet (0,5) joue un rôle de régularisation efficace, limitant sa sensibilité à la variabilité stochastique de l'initialisation et du volume de données restreint, contrairement à EEGNet, dont l'instabilité constitue une limite pratique importante pour un déploiement clinique où la fiabilité individuelle du système est essentielle.

Les courbes d'entraînement et de validation obtenues sur l'un des profils illustrent cette différence de comportement. Pour EEGNet, l'entraînement converge rapidement vers 90-97 %, tandis que la validation plafonne entre 55 % et 75 % selon le fold, avec une forte instabilité. Pour DeepConvNet, l'entraînement converge aussi vers 100 %, mais la validation se stabilise plus régulièrement entre 45 % et 65 %, avec une progression moins erratique qu'EEGNet. Cette régularité contraste toutefois avec la bonne généralisation (écart train/val faible) observée pour DeepConvNet sur les données humides, suggérant que le volume de données d'entraînement limité freine sa capacité à généraliser aussi efficacement, malgré une meilleure stabilité que EEGNet sur ces données.




Figure 35 : Courbes d'entraînement et de validation pour EEGNet (haut) et DeepConvNet (bas) sur le Sujet 01 (données Kaptics).

5.3.2 Comparaison inter-systèmes (électrodes sèches vs humide) :

Cette section compare directement les performances obtenues avec les systèmes à électrodes humides et à électrodes sèches (Kaptics) pour les trois classifieurs évalués.

Tableau 13 : Comparaison des accuracies moyennes entre systèmes à électrodes humides et sèches (Kaptics).

Classifieur	Électrodes humides (%)	Électrodes sèches — Kaptics (%)	Écart (points)
RLDA	79,3	60,1	-19,2
EEGNet	70,1	58,6	-11,5
DeepConvNet	69,5	56,8	-12,7

Les trois classifieurs présentent une baisse de performance sur les données Kaptics par rapport aux données à électrodes humides, avec des écarts variant de 11,5 à 19,2 points selon la méthode. Cette baisse généralisée est cohérente avec les attentes formulées en amont du projet : les électrodes sèches, bien qu'avantageuses sur le plan pratique (temps de préparation réduit, absence de gel conducteur), sont connues pour offrir un contact électrode-peau généralement moins stable que les électrodes humides, ce qui se traduit typiquement par un rapport signal/bruit inférieur.

L'écart le plus marqué concerne RLDA, qui perd 19,2 points en passant des données humides aux données Kaptics, soit près de deux fois l'écart observé pour EEGNet et DeepConvNet. Ce résultat est notable, dans la mesure où RLDA bénéficiait sur les données humides d'un avantage structurel lié à l'adéquation entre le format des données (features PSDAG précalculées, filtre A1013) et les hypothèses du classifieur, comme discuté en section 6.1.1. L'absence de ce même avantage structurel sur les données Kaptics, où RLDA opère sur des features extraites directement du signal brut sans prétraitement spécifique au classifieur, explique en partie pourquoi cette méthode est proportionnellement plus affectée par le changement de système. EEGNet et DeepConvNet, conçus dès l'origine pour opérer sur signal brut, ne bénéficiaient pas de cet avantage sur les données humides et sont donc moins pénalisés par ce changement de contexte.

CHAPITRE 6 DISCUSSION

6.1 Résultats sur les données à électrodes humides :

6.1.1 Performance des classifieurs et comparaison inter-méthodes :

Le premier constat est que RLDA surpasse les deux architectures de deep learning dans toutes les configurations testées, avec une précision moyenne de 79,3 % contre 70,1 % pour EEGNet et 69,5 % pour DeepConvNet. Ce résultat, à première vue contre-intuitif dans un contexte où les architectures profondes dominent souvent le traitement du signal, s'explique par les caractéristiques des données disponibles : RLDA opère sur des features spectrales compactes extraites sur une fenêtre fixe, ce qui lui permet d'apprendre efficacement avec peu de trials, et sa régularisation par shrinkage (0,4) limite le surapprentissage même quand le rapport features/exemples est défavorable, un cas fréquent en EEG. Cette compétitivité des classifieurs linéaires régularisés face aux approches profondes, quand le volume d'entraînement est limité, est bien documentée dans la littérature BCI.

Cette supériorité doit toutefois être nuancée par un biais structurel des données disponibles. Celles-ci ont été prétraitées et structurées par Alchalabi et al. (2021) exclusivement pour RLDA : le filtre A1013 (10-13 Hz), les features PSDAG précalculées et la segmentation en fenêtres fixes reflètent des choix de conception propres à ce classifieur. EEGNet et DeepConvNet, conçus pour opérer sur signal brut continu et apprendre leurs propres représentations, ne peuvent pas exploiter pleinement leur capacité face à des données déjà filtrées et segmentées selon une logique RLDA. La supériorité observée reflète donc en partie cette concordance entre format des données et hypothèses du classifieur, plutôt qu'un avantage intrinsèque de la méthode.

La tâche BCI_WALK obtient par ailleurs systématiquement de meilleures performances que BCI_STEPS pour RLDA, avec un écart moyen d'environ 12 points, reflétant leur différence de complexité : une classification binaire (imagerie de marche vs repos) contre une discrimination à trois classes (pas droit, pas gauche, repos).

6.1.2 Effet de l'accumulation des sessions :

RLDA, EEGNet et DeepConvNet bénéficient tous de l'ajout de données provenant de sessions supplémentaires, à des degrés différents. RLDA reste très stable (78,8 % à 80,0 % selon la configuration). EEGNet gagne jusqu'à 5,3 points entre le Jour 1 seul (68,3 %) et Jours 1+3 (73,6 %). DeepConvNet suit une trajectoire similaire mais plus modeste, avec un gain de 3,8 points (68,4 % à 72,2 %), contrairement aux observations initiales qui suggéraient une dégradation avec la fusion des sessions, confirmant que cette architecture en bénéficie aussi, dans une moindre mesure qu'EEGNet.

Cet écart de gain s'explique par la complexité architecturale plus élevée de DeepConvNet, qui exige davantage de données pour exploiter pleinement la diversité inter-session, alors qu'EEGNet, plus léger, tire parti plus efficacement de chaque exemple supplémentaire. Les courbes d'entraînement pour Subj05 en Jour 1 (Figures 32 et 33, Chapitre 5) vont dans ce sens : DeepConvNet y montre une convergence train/validation plus rapprochée, signe d'une meilleure stabilité de généralisation dès une seule session, qui continue de s'améliorer avec l'ajout de données.

En mono-session, EEGNet et DeepConvNet atteignent un niveau presque identique (68,3 % et 68,4 % au Jour 1), et c'est surtout en multisession que leurs comportements divergent légèrement, EEGNet en tirant davantage profit.

Cette différence se manifeste aussi dans les courbes individuelles d'EEGNet : l'expert hiérarchique (RIGHT/LEFT/WALK) montre un écart marqué entre entraînement (0,95-0,98) et validation (0,3-0,6, avec une forte instabilité) (Figure 12, Chapitre 5 ; Figures-A II 1 à 4, Annexe II, pour Subj05, Subj08 et Subj12), contrastant avec la convergence stable du gate (IDLE vs MOVE). Cette différence entre les deux étages illustre l'effet du volume de données : la discrimination binaire IDLE/MOVE, plus simple et mieux dotée en exemples, permet une bonne généralisation, tandis que la discrimination fine entre les trois mouvements, avec seulement ~165 trials par classe avant

augmentation, ne fournit pas assez d'exemples réels pour que le réseau apprenne des représentations généralisables plutôt que de mémoriser le set d'entraînement.

6.1.3 Robustesse face à la qualité du signal :

L'analyse individuelle des sujets a révélé une variabilité de qualité de signal d'un sujet à l'autre, qui n'affecte pas les trois méthodes de la même façon. RLDA se distingue par une robustesse notable : des sujets avec moins de 40 % de trials valides, comme Subj12, maintiennent des performances RLDA au-dessus de 0,750, et Subj10, dont le Jour 3 présente une saturation complète d'un canal critique, atteint 0,773 sur cette même session. Cette robustesse tient à deux facteurs : le calcul des features sur une fenêtre fixe centrée sur la période d'imagerie, qui limite l'exposition aux artefacts hors de cette fenêtre, et la régularisation du classifieur, qui atténue l'influence des canaux bruités. EEGNet et DeepConvNet, qui opèrent directement sur le signal brut filtré sans extraction intermédiaire de features, sont plus exposés aux artefacts résiduels et aux anomalies ponctuelles. Ce constat a des implications pour leur déploiement sur des données dont la qualité de signal est moins homogène, comme celles issues d'électrodes sèches.

6.1.4 Comparaison avec les travaux existants :

La comparaison la plus directe est celle avec l'étude originale d'Alchalabi et al. (2021), dont les données constituent la base de référence de ce projet. Dans cette étude, le classifieur RLDA atteignait une précision hors ligne moyenne de 86.0 ± 6.1 % après recalibrage sur quatre sessions d'acquisition. Les performances RLDA obtenues dans ce projet, de l'ordre de 72.7 % à 78.2 % selon la configuration de jours utilisée, sont inférieures à cette référence. Cet écart s'explique par plusieurs différences méthodologiques documentées en section 6.4 : l'absence de débruitage ICA+MARA, l'utilisation d'un filtre centré sur la bande 10-13 Hz plutôt que d'un filtre optimisé par participant, et l'absence de sélection de la fenêtre temporelle optimale parmi plusieurs candidats. Malgré cela, la progression observée avec l'accumulation des sessions est cohérente avec le comportement rapporté par Alchalabi et al. (2021), qui observaient une amélioration significative des performances au fil des sessions grâce au recalibrage séquentiel des classifieurs.

Sur le plan des méthodes de classification classiques, les performances RLDA obtenues dans ce projet sont cohérentes avec les valeurs rapportées dans la littérature BCI pour des tâches d'imagerie motrice à trois classes. Lotte et al. (2007) rapportent des précisions de l'ordre de 93 à 97 % pour la RLDA sur des tâches main gauche contre main droite, mais ces résultats portent sur une discrimination binaire dans des conditions optimales d'acquisition. La tâche évaluée dans ce projet est structurellement plus difficile, impliquant trois classes de mouvements des membres inférieurs avec une classe de repos et un signal EEG moins discriminant que pour les mouvements des membres supérieurs. Dans ce contexte, des performances de l'ordre de 75 % constituent un résultat solide et cohérent avec les travaux sur l'imagerie motrice des membres inférieurs, notamment Boord et al. (2010) qui rapportent des taux de classification de 72 à 83 % pour la discrimination gauche/droite du membre inférieur.

Concernant les architectures d'apprentissage profond, les performances d'EEGNet obtenues dans ce projet sont inférieures aux résultats rapportés par Lawhern et al. (2018) sur des paradigmes BCI standards, mais cette comparaison doit être nuancée par les conditions d'utilisation sensiblement différentes. Le gain observé avec la fusion des sessions est en revanche cohérent avec les observations de Roy et al. (2019), qui soulignent que les architectures d'apprentissage profond bénéficient davantage de l'augmentation du volume de données que les méthodes classiques, sous réserve que la complexité du modèle soit adaptée au volume disponible. Le comportement de DeepConvNet est quant à lui cohérent avec les observations de Schirrmester et al. (2017), qui soulignent que cette architecture nécessite un volume de données important pour généraliser correctement et que son avantage sur EEGNet est principalement observable avec des datasets de grande taille.

6.2 Résultats sur les données à électrodes sèches (Kaptics) :

6.2.1 Performance des classifieurs :

Les résultats obtenus sur les données Kaptics révèlent un changement notable dans la hiérarchie des classifieurs par rapport aux données à électrodes humides. Alors que RLDA surpassait nettement les deux architectures d'apprentissage profond sur les données humides (écart de 9,2

points avec EEGNet, 9,8 points avec DeepConvNet), les trois classifieurs obtiennent sur Kaptics des performances moyennes beaucoup plus proches, comprises entre 56,8 % et 60,1 %. Cette convergence s'explique en grande partie par la disparition du biais structurel qui avantageait RLDA sur les données humides : les trois pipelines opèrent ici sur un même signal brut filtré, sans qu'aucune méthode ne bénéficie d'un prétraitement conçu spécifiquement pour elle.

Le résultat le plus instructif de cette section concerne toutefois la stabilité inter-sujets plutôt que la performance moyenne elle-même. RLDA et DeepConvNet présentent une variabilité restreinte et comparable (écarts-types de 3,2 et 3,1 points respectivement), tandis qu'EEGNet affiche une variabilité près de cinq fois supérieure (15,1 points), avec un sujet dont la performance ne dépasse pas le niveau de chance (33,6 %). Cette instabilité d'EEGNet, illustrée par l'écart marqué entre courbes d'entraînement et de validation observé pour le Sujet 01, constitue un enseignement pratique important : la performance moyenne d'un classifieur ne suffit pas à elle seule à juger de son adéquation pour un déploiement réel, où la fiabilité doit être garantie à l'échelle individuelle plutôt qu'en moyenne sur un groupe de sujets.

Le comportement de DeepConvNet mérite une attention particulière à ce titre. Bien que cette architecture affiche une stabilité inter-sujets comparable à celle de RLDA, l'analyse des courbes d'entraînement révèle un écart train/validation important et persistant sur l'ensemble des folds, les courbes de validation se stabilisant entre 45 % et 65 % alors que l'entraînement converge systématiquement vers des valeurs proches de 100 %. Ce comportement contraste avec la bonne généralisation observée pour DeepConvNet sur les données humides (section 6.1.2), et suggère que le volume de données d'entraînement disponible sur Kaptics, plus restreint qu'un protocole idéal, limite la capacité de cette architecture à exploiter pleinement sa capacité de représentation, malgré une stabilité inter-sujets qui masque en partie cette limitation lorsqu'on ne considère que l'accuracy finale.

6.2.2 Impact de la qualité du signal sur la classification :

Le protocole Kaptics présente des caractéristiques de qualité de signal structurellement différentes de celles des électrodes humides. L'absence de gel conducteur, propre aux électrodes sèches, se traduit typiquement par un contact électrode-peau plus variable et une impédance plus sensible aux mouvements et à la transpiration, ce qui peut introduire davantage de bruit et d'artefacts transitoires dans le signal brut. Contrairement au pipeline RLDA appliqué aux données humides,

qui bénéficiait de features spectrales précalculées sur des fenêtres optimisées et d'un débruitage en amont, le pipeline Kaptics repose sur une extraction de caractéristiques directement à partir du signal brut, sans étape de débruitage avancé ni vérification d'impédance en temps réel pendant l'acquisition.

Cette contrainte méthodologique limite la capacité à isoler précisément la part de variabilité inter-sujets attribuable à la qualité intrinsèque du signal plutôt qu'à d'autres facteurs, tels que l'engagement dans la tâche d'imagerie motrice ou la variabilité individuelle de la modulation cérébrale. L'instabilité marquée observée pour EEGNet pourrait ainsi refléter, au moins en partie, une sensibilité accrue de cette architecture aux artefacts résiduels non filtrés, comparée à RLDA dont la régularisation par shrinkage atténue l'influence des canaux bruités sur la décision finale, comme déjà discuté en section 6.1.3 pour les données humides. Une analyse de qualité de signal plus poussée, incluant une mesure d'impédance systématique par électrode et un suivi en temps réel pendant l'acquisition, permettrait de mieux isoler cette variable pour des travaux futurs.

6.3 Comparaison inter-systèmes (électrodes sèches vs humides) :

6.3.1 Performances relatives des trois classifieurs :

La comparaison directe entre systèmes révèle une baisse de performance généralisée sur les données Kaptics, avec des écarts de 19,2 points pour RLDA, 11,5 points pour EEGNet et 12,7 points pour DeepConvNet par rapport aux données humides (Tableau 13). Cette baisse est cohérente avec les attentes formulées en amont du projet quant aux limites inhérentes aux électrodes sèches en matière de qualité de contact et de rapport signal/bruit.

L'écart proportionnellement plus marqué pour RLDA mérite une attention particulière : plutôt que de refléter une limite intrinsèque des électrodes sèches, il illustre principalement la disparition de l'avantage structurel dont bénéficiait RLDA sur les données humides, où le format des données (features PSDAG précalculées, filtre A1013) était directement conçu pour ce classifieur. Ce constat nuance l'interprétation d'une supériorité générale de RLDA établie en 6.1.1 : cette supériorité était en grande partie conditionnelle au format des données disponibles, plutôt qu'une propriété intrinsèque de la méthode. Sur des données traitées de façon plus neutre, comme c'est le cas avec Kaptics, l'écart entre approches classiques et approches profondes se réduit nettement,

EEGNet et DeepConvNet, conçus dès l'origine pour opérer sur signal brut, n'ayant jamais bénéficié de cet avantage structurel et étant donc proportionnellement moins pénalisés par le changement de système.

Il convient toutefois de nuancer cette comparaison par une différence de protocole expérimental déjà documentée en 6.4.3 : l'acquisition Kaptics a été réalisée en une seule session par participant, alors que les données humides bénéficient d'une accumulation sur plusieurs jours, dont la section 6.1.2 a montré qu'elle améliore les performances de RLDA et d'EEGNet de plusieurs points. Une partie de l'écart observé entre les deux systèmes pourrait donc refléter non pas une limitation intrinsèque du matériel Kaptics, mais l'absence d'opportunité d'accumulation de sessions dans le protocole tel qu'il a été mis en œuvre dans ce projet.

6.3.2 Comparaison avec la littérature :

Peu d'études ont comparé directement les performances de classification entre électrodes sèches et humides pour l'imagerie motrice, la plupart des travaux existants se concentrant sur la comparaison de la qualité du signal brut (amplitude, impédance, rapport signal-bruit) plutôt que sur l'impact réel en aval sur la classification. Jeong et al. (2021) constituent l'une des rares exceptions directement comparables à ce projet : leur étude porte sur l'imagerie motrice des membres inférieurs (marche, position assise, repos), avec des données acquises sur les mêmes sujets à l'aide des deux types d'électrodes, et une comparaison de plusieurs classifieurs incluant FBCSP (une méthode classique proche de RLDA dans sa logique d'extraction de caractéristiques), EEGNet et DeepConvNet.

Leurs résultats montrent un écart de performance entre électrodes sèches et humides de 10,15 points pour FBCSP, contre seulement 3,87 points pour EEGNet et 3,26 points pour DeepConvNet. Les auteurs interprètent cette différence par la plus grande robustesse des architectures profondes face au bruit induit par le contact imparfait des électrodes sèches, les couches convolutives apprenant potentiellement des représentations moins sensibles aux perturbations locales du signal que les caractéristiques spectrales fixes utilisées par les méthodes classiques.

Cette tendance, où les méthodes classiques souffrent proportionnellement plus du changement de système d'acquisition que les architectures profondes, se retrouve dans les résultats obtenus ici sur les données Kaptics : l'écart pour RLDA (19,2 points) reste supérieur à celui d'EEGNet (11,5

points) et de DeepConvNet (12,7 points). L'amplitude des écarts observés dans ce projet est toutefois nettement supérieure à celle rapportée par Jeong et al. (2021), ce qui peut s'expliquer par plusieurs différences méthodologiques : leur protocole comparait les deux systèmes chez les mêmes sujets lors de sessions consécutives réalisées le même jour, alors que les données humides et Kaptics de ce projet proviennent de cohortes de participants différentes et de protocoles d'acquisition non strictement comparables. Cette différence limite la portée de la comparaison directe des écarts absolus entre les deux études, mais renforce la cohérence qualitative observée quant à la robustesse relative des différentes méthodes de classification face au changement de type d'électrodes

6.3.3 Faisabilité clinique des électrodes sèches :

D'un point de vue pratique, les électrodes sèches conservent des avantages clairs pour un déploiement clinique répété : absence de gel conducteur, temps de préparation réduit, confort accru pour le patient, autant de facteurs importants pour l'adoption d'un système destiné à des séances régulières de réadaptation.

Sur le plan de la performance, les résultats obtenus (56,8 % à 60,1 % selon le classifieur) restent nettement supérieurs au niveau de chance et démontrent la faisabilité technique de la détection d'un signal moteur discriminant avec ce type d'électrodes. Ces performances demeurent toutefois inférieures à celles obtenues avec les électrodes humides, et probablement insuffisantes en l'état pour un usage clinique nécessitant une fiabilité élevée et constante, condition essentielle pour garantir la confiance du patient dans le système et l'efficacité thérapeutique de la rétroaction. La variabilité inter-sujets marquée d'EEGNet constitue à cet égard une réserve importante : un système dont la fiabilité varie fortement d'un individu à l'autre, y compris jusqu'à un niveau proche du hasard pour un sujet, est difficilement déployable à grande échelle sans calibration individuelle poussée. RLDA et DeepConvNet, par leur stabilité inter-sujets supérieure, apparaissent à ce titre comme des choix plus prudents pour une première implémentation clinique, malgré une performance moyenne légèrement inférieure pour DeepConvNet.

6.4 Limites de l'étude :

Plusieurs limites méthodologiques doivent être prises en compte dans l'interprétation des résultats de ce mémoire, concernant la nature des données disponibles, le protocole d'acquisition et la portée des conclusions.

6.4.1 Contraintes liées aux données à électrodes humides :

La première limite concerne les données de référence issues des travaux d'Alchalabi et al. (2021). En raison d'un problème de stockage lors du transfert, l'accès au signal EEG brut continu n'a pas été possible : les données disponibles sont déjà segmentées et partiellement prétraitées, accompagnées de features spectrales précalculées. Le pipeline de prétraitement original n'est que partiellement documenté : si l'usage d'un filtre IIR personnalisé (A1013, bande 10-13 Hz) est connu, les paramètres exacts de filtrage analogique, de référencement et de rejet d'artefacts en amont de la segmentation restent inaccessibles, empêchant de reproduire ou d'évaluer ce prétraitement, ce qui limite la reproductibilité de l'analyse.

Cette absence de signal brut a aussi empêché l'application d'EEGNet et de DeepConvNet dans leurs conditions optimales : les données avaient été structurées exclusivement pour RLDA, seule méthode pertinente au moment de l'étude originale, et les segments prédécoupés, les features PSDAG et le filtre A1013 reflètent tous des choix propres à ce pipeline. Appliqués à des données déjà segmentées pour un autre classifieur, EEGNet et DeepConvNet ne peuvent pas exploiter pleinement leur capacité d'apprentissage. L'architecture gate+expert développée pour ce projet constitue une adaptation nécessaire à cette contrainte, mais s'écarte des implémentations de référence de la littérature, ce qui limite la comparabilité directe des résultats.

6.4.2 Données manquantes et runs incomplets :

La seconde limite concerne le volume de données effectivement disponibles par rapport au protocole théorique. Chaque participant de l'étude de référence devait réaliser 4 sessions de 10 runs chacune, pour un total théorique de 40 runs par sujet. En pratique, les fichiers transmis par l'ancien doctorant présentent des lacunes importantes : un minimum de 2 runs manquent systématiquement par session pour la majorité des sujets, et certains cas sont plus sévères, comme Subj07 dont le Jour 3 ne compte que 4 runs récupérables, ou Subj06 dont le Jour 3 est entièrement absent. Ces données manquantes ne résultent pas d'abandons de participants ou de problèmes

d'acquisition, mais d'un problème de stockage et d'organisation des fichiers lors de la sauvegarde des données originales : une partie des runs n'a pas été correctement archivée et n'est plus accessible. Cette réduction du volume de données disponibles par rapport au protocole prévu affecte directement la robustesse des estimations de performance, en particulier pour les architectures d'apprentissage profond qui sont plus sensibles au volume d'exemples d'entraînement, et constitue une limite inhérente aux données héritées plutôt qu'au protocole expérimental lui-même.

6.4.3 Contraintes liées au protocole Kaptics :

Pour les données à électrodes sèches Kaptics, deux limites principales doivent être mentionnées. D'abord, l'acquisition a été réalisée en une seule session par participant, contrairement au protocole multisessions d'Alchalabi et al. (2021), qui comprenait quatre journées d'acquisition. Cette différence limite la comparaison directe entre les deux systèmes, puisque les bénéfices de l'accumulation inter-session documentés pour les données humides ne peuvent pas être évalués pour Kaptics.

Ensuite, le protocole Kaptics est passif : les mouvements de l'avatar sont déclenchés par l'expérimentateur selon un scénario prédéfini, indépendamment de ce que le participant imagine. Cette approche, justifiée par la nécessité de collecter des données dans des conditions stables et reproductibles, diffère du protocole en boucle fermée d'Alchalabi et al. (2021), où c'était l'activité cérébrale du participant qui pilotait directement l'avatar. L'absence de ce retour sensoriel pourrait réduire l'engagement et la précision de l'imagerie motrice, avec des effets potentiels sur la qualité des modulations EEG produites.

6.4.4 Portée des conclusions :

Toutes les acquisitions de ce projet ont été menées auprès de participants sains, tant pour Kaptics que pour le système de référence. La transférabilité à une population clinique de patients en réadaptation motrice reste à démontrer : les patients présentent généralement une variabilité EEG plus importante, une fatigue plus rapide, et des difficultés potentiellement plus grandes à maintenir une imagerie motrice de qualité sur la durée d'une session, autant de facteurs qui pourraient

modifier les performances relatives des méthodes évaluées. Le nombre de participants reste par ailleurs limité, soit cinq pour Kaptics et neuf pour le système de référence, ce qui restreint la portée statistique des conclusions et leur généralisation à une population plus large.

CONCLUSION

Ce projet a évalué la faisabilité d'un système BCI basé sur l'imagerie motrice pour la réadaptation, en comparant deux systèmes d'acquisition EEG, à électrodes humides et à électrodes sèches (Kaptics), à travers trois classifieurs : RLDA, EEGNet et DeepConvNet.

Sur les données à électrodes humides, RLDA s'est révélé le plus performant (79,3 % en moyenne), devançant EEGNet et DeepConvNet de 9 à 10 points. Cette supériorité s'est toutefois avérée en partie liée au format des données, prétraitées spécifiquement pour ce classifieur, plutôt qu'à un avantage intrinsèque de la méthode. Sur les données Kaptics, les trois classifieurs ont obtenu des performances beaucoup plus rapprochées (56,8 % à 60,1 %), confirmant cette hypothèse, mais avec une baisse générale de 11,5 à 19,2 points par rapport aux électrodes humides. Un résultat marquant concerne la stabilité inter-sujets : RLDA et DeepConvNet se sont montrés robustes, tandis qu'EEGNet a présenté une variabilité nettement plus importante, jusqu'à une performance proche du hasard pour un sujet, soulignant que la fiabilité individuelle est un critère aussi important que la performance moyenne pour un contexte clinique.

Ces résultats indiquent que les électrodes sèches constituent une alternative techniquement viable aux électrodes humides, mais avec des performances actuellement inférieures et probablement insuffisantes pour un déploiement clinique immédiat. Leurs avantages pratiques, temps de préparation réduit, absence de gel conducteur, confort pour le patient, restent néanmoins des arguments solides pour une utilisation en réadaptation, sous réserve d'améliorations méthodologiques.

Le protocole Kaptics, réalisé en une seule session, n'a pas permis d'évaluer les bénéfices de l'accumulation multisession observés sur les données humides, et son caractère passif pourrait avoir réduit l'engagement des participants. L'ensemble des acquisitions portait par ailleurs sur des sujets sains, limitant la transférabilité à une population clinique. Des travaux futurs pourraient porter sur un protocole multisession, un meilleur contrôle du contact électrode-peau, et une validation sur un échantillon plus large incluant des patients.

ANNEXE I

ANALYSE DE LA QUALITÉ DES DONNÉES EEG ET SÉLECTION DES SUJETS

I.1 Critères d'évaluation des sujets

Afin d'assurer la fiabilité des expériences de classification, une analyse individuelle des sujets a été réalisée avant l'entraînement des modèles. Cette analyse repose sur trois critères complémentaires permettant d'évaluer la qualité et la quantité des données EEG disponibles : le nombre de runs par session, le taux de trials conservés après rejet des artefacts au seuil de 150 μ V, et les performances obtenues avec le classifieur RLDA lors d'une validation croisée à dix plis.

Tableau I-1 : Critères utilisés pour l'évaluation de la qualité des données EEG des sujets.

Critère	Description	Seuils d'évaluation
Nombre de runs disponibles	Évalue la quantité de données EEG disponibles par session. Le protocole théorique prévoit 10 runs par session, soit 300 trials.	≥ 8 runs : satisfaisant
		6-7 runs : attention
		≤ 5 runs : problématique
% Trials valides après rejet des artefacts	Proportion d'essais conservés après suppression des segments contenant des artefacts supérieurs à 150 μ V.	≥ 80 % : satisfaisant
		50-80 % : attention
		< 50 % : problématique
Accuracy RLDA (validation croisée à 10 plis)	Évalue la séparabilité des classes d'imagerie motrice. Une accuracy élevée indique que les modulations cérébrales sont discriminantes.	≥ 0.73 : satisfaisant
		0.71-0.73 : attention
		< 0.71 : problématique

I.2 Résultats détaillés de sélection

Un script automatique développé spécifiquement pour ce projet (selection_sujet.py) permet de synthétiser les caractéristiques de chaque sujet selon les trois critères définis en I.1, afin d'identifier ceux pouvant être inclus dans les différentes expériences de classification. Pour chaque sujet et chaque jour de session, le script calcule le nombre de runs disponibles, le pourcentage de trials conservés après rejet des artefacts au seuil de 150 μ V, et les performances RLDA obtenues par validation croisée à dix plis. Un code couleur à trois niveaux (vert, orange, rouge) est appliqué automatiquement à chaque indicateur pour faciliter l'identification visuelle des sujets problématiques.

Tableau I-2 : Analyse individuelle des sujets selon la disponibilité des données EEG, le taux de trials valides après rejet des artefacts et les performances RLDA obtenues par validation croisée.

SUJET	RUNS DISPONIBLES			TRIALS PAR JOUR			% TRIALS VALIDES			ACCURACY RLDA			PROGRESSION	INCLUSION
	J1	J2	J3	J1	J2	J3	J1	J2	J3	J1	J2	J3	J1→J3	
Subj05	8	9	8	237	268	230	73.8 %	89.6 %	84.3 %	0.715	0.761	0.772	+5.7 %	RLDA + DL
Subj06	9	9	—	267	267	0	29.6 %	50.6 %	vide	0.740	0.758	N/A	J3 absent	RLDA + DL
Subj07	9	8	4	270	196	111	83.0 %	94.4 %	96.4 %	0.723	0.748	0.777	+5.4 %	RLDA + DL
Subj09	9	8	8	255	236	238	83.5 %	93.2 %	95.8 %	0.732	0.738	0.766	+3.4 %	RLDA + DL
Subj10	9	8	8	259	234	230	95.4 %	91.0 %	0.0 %	0.744	0.751	0.773	+2.9 %	RLDA + DL *
Subj11	10	6	6	253	145	175	34.8 %	79.3 %	68.6 %	0.725	0.722	0.751	+2.6 %	RLDA + DL
Subj12	9	9	7	225	240	206	18.2 %	13.3 %	38.3 %	0.712	0.763	0.752	+5.1 %	RLDA + DL
Subj17	8	6	7	202	164	207	80.2 %	62.2 %	23.7 %	0.727	0.752	0.758	+3.1 %	RLDA + DL
Subj18	10	8	7	297	238	182	29.3 %	87.4 %	62.1 %	0.729	0.752	0.719	-1.0 %	RLDA seul

■ Satisfaisant ($\geq 80\%$ / ≥ 0.73)
 ■ Attention ($50-80\%$ / $0.71-0.73$)
 ■ Problématique ($< 50\%$ / < 0.71)
 * J3 exclu du pipeline DL (C4 saturé)

ANNEXE II

RÉSULTATS COMPLÉMENTAIRES DE CLASSIFICATION

Cette annexe présente les résultats détaillés des expériences de classification, organisés par sujet et par configuration de sessions. Elle complète les résultats synthétiques présentés au Chapitre 5.

II.1 Performances selon les configurations de sessions

Les tableaux suivants présentent les performances individuelles obtenues pour chaque sujet avec les trois méthodes de classification évaluées, selon les différentes combinaisons de jours d'enregistrement utilisées pour l'entraînement. Ces résultats permettent d'apprécier à la fois la variabilité inter-sujet et l'effet de l'accumulation des sessions sur chaque algorithme

Tableau II-1 : Performances individuelles du modèle RLDA selon les configurations de sessions.

Sujet	J1	J2	J3	J1+2	J1+3	J2+3	J1+2+3
Subj04	80.3 %	77.4 %	80.0 %	80.4 %	80.3 %	80.3 %	80.3 %
Subj05	78.0 %	79.4 %	79.3 %	79.5 %	79.7 %	80.2 %	80.1 %
Subj06	80.0 %	79.3 %	—	80.0 %	80.0 %	79.3 %	80.0 %
Subj07	78.9 %	79.1 %	78.2 %	79.8 %	79.1 %	79.4 %	79.8 %
Subj08	80.2 %	79.8 %	79.7 %	80.3 %	80.2 %	80.3 %	80.5 %
Subj09	79.9 %	79.8 %	80.3 %	79.9 %	80.1 %	80.1 %	80.1 %
Subj10	79.5 %	79.0 %	80.3 %	79.7 %	80.3 %	80.4 %	80.4 %
Subj11	79.7 %	—	—	79.7 %	79.7 %	—	79.7 %
Subj12	79.7 %	80.0 %	80.1 %	80.2 %	80.3 %	80.3 %	80.3 %
Subj15	79.6 %	—	79.9 %	79.6 %	79.8 %	79.9 %	79.8 %
Subj17	78.2 %	—	—	78.2 %	78.2 %	—	78.2 %
Subj18	79.4 %	79.6 %	78.4 %	80.3 %	80.3 %	79.5 %	80.2 %
Subj19	70.8 %	—	—	70.8 %	70.8 %	—	70.8 %
Moyenne	78.8 %	79.3 %	79.6 %	79.1 %	79.1 %	80.0 %	79.2 %

Tableau II-2 : Performances individuelles du modèle EEGNet selon les configurations de sessions.


Sujet	J1	J2	J3	J1+2	J1+3	J2+3
Subj04	68.3 %	66.7 %	71.7 %	71.7 %	73.3 %	72.5 %
Subj05	66.7 %	63.3 %	68.3 %	70.8 %	72.5 %	72.5 %
Subj07	65.0 %	66.0 %	68.3 %	70.8 %	73.3 %	72.5 %
Subj08	73.1 %	68.3 %	65.0 %	73.3 %	75.0 %	74.2 %
Subj09	71.7 %	68.3 %	61.7 %	71.7 %	73.3 %	73.3 %
Subj10	66.7 %	71.7 %	66.7 %	71.7 %	73.3 %	72.5 %
Subj12	70.0 %	63.3 %	66.7 %	73.3 %	75.8 %	74.2 %
Subj17	64.6 %	66.7 %	70.0 %	70.8 %	72.5 %	72.5 %
Subj18	68.3 %	66.7 %	66.7 %	72.5 %	73.5 %	73.0 %
Moyenne	68.3 %	66.8 %	67.2 %	71.8 %	73.6 %	73.0 %

Tableau II-3 : Performances individuelles du modèle DeepConvNet selon les configurations de sessions.


Sujet	J1	J2	J3	J1+2	J1+3	J2+3
Subj04	68.3 %	68.7 %	70.0 %	68.3 %	70.0 %	68.3 %
Subj05	70.0 %	71.7 %	68.3 %	71.7 %	73.3 %	70.0 %
Subj07	61.7 %	50.0 %	61.7 %	68.3 %	68.3 %	68.3 %
Subj08	65.4 %	66.7 %	70.0 %	70.0 %	71.7 %	68.3 %
Subj09	68.3 %	65.0 %	60.0 %	68.3 %	68.3 %	66.7 %
Subj10	75.0 %	76.7 %	65.0 %	75.0 %	76.7 %	75.0 %
Subj12	66.7 %	75.0 %	73.3 %	73.3 %	75.0 %	73.3 %
Subj17	66.7 %	67.7 %	70.0 %	70.0 %	71.7 %	70.0 %
Subj18	73.3 %	70.0 %	65.0 %	75.0 %	75.0 %	75.0 %
Moyenne	68.4 %	67.9 %	67.0 %	71.1 %	72.2 %	70.5 %

II.2 Courbes d'entraînement :


Les figures suivantes présentent les courbes d'entraînement et de validation pour EEGNet et DeepConvNet sur Subj08 et Subj12, configuration Jour 1, en complément des courbes présentées au Chapitre 5 pour Subj05.




DeepConvNet — Courbes d'entraînement
Sujet : Subj08 | Configuration : Jour 1



EEGNet — Courbes d'entraînement
Sujet : Subj12 | Configuration : Jour 1



DeepConvNet — Courbes d'entraînement
Sujet : Subj12 | Configuration : Jour 1



ANNEXE III PARAMÈTRES DES MODÈLES DE CLASSIFICATION

Cette annexe présente les paramètres utilisés pour l'entraînement et l'évaluation des différents modèles de classification EEG. Les hyperparamètres détaillés pour les approches RLDA, EEGNet et DeepConvNet sont fournis afin d'assurer la reproductibilité des expériences réalisées.

III.1 Paramètres du modèle RLDA

La méthode RLDA (Regularized Linear Discriminant Analysis) a été utilisée comme méthode de référence pour la classification des signaux EEG. Les paramètres principaux utilisés lors de l'entraînement et de l'évaluation sont présentés dans le tableau suivant.

Tableau III-1 : Paramètres utilisés pour la classification avec le modèle RLDA.

Paramètre	Valeur
Méthode de régularisation	Shrinkage fixe
Coefficient de régularisation	$\lambda = 0.4$
Stratégie de validation	Validation croisée stratifiée à 10 plis
Bande de fréquence	10-13 Hz (filtre A1013, bande mu supérieure)
Fenêtre temporelle	move1 (256 échantillons, ~1050-1306 ms)
Features extraites	PSDAG (645 dimensions)
Fenêtres de repos	nomove1 et nomove2 (classe IDLE)
Classes cibles	IDLE (0), RIGHT (1), LEFT (2), WALK (3)
Normalisation	Z-score anti-leakage sur données d'entraînement

III.2 Paramètres du modèle EEGNet :

Le modèle EEGNet a été entraîné afin d'exploiter les représentations spatiales et temporelles des signaux EEG. Les paramètres architecturaux et d'apprentissage utilisés sont résumés ci-dessous.

Tableau III-2 : Hyperparamètres du modèle EEGNet.

Paramètre	Valeur
Architecture	Gate + Expert (hiérarchique 2 étages)
Filtres temporels (F1)	8
Profondeur spatiale (D)	2
Filtres séparables (F2)	16

Kernel temporel gate	128 samples (~500 ms)
Kernel temporel expert	192 samples (~750 ms)
Taux de dropout	0.25
Fonction d'activation	ELU
Optimiseur	Adam
Taux d'apprentissage	5×10^{-4}
Scheduler	ReduceLROnPlateau
Weight decay	1×10^{-4}
Taille de batch	64
Epochs maximum	200
Patience early stopping	40 epochs
Bande de fréquence	13-30 Hz (bande bêta)
Augmentation	$\times 6$ (bruit gaussien $\sigma=0.05$ + décalage ± 25 samples)
Stratégie de validation	LORO (Leave-One-Run-Out)
Classes cibles	IDLE (0), RIGHT (1), LEFT (2), WALK (3)

III.3 Paramètres du modèle DeepConvNet

Le modèle DeepConvNet a été utilisé comme architecture de référence basée sur des réseaux convolutionnels profonds. Les paramètres d'architecture et d'apprentissage présentés dans le tableau suivant correspondent à la configuration utilisée pour les résultats sur les données humides rapportés dans ce mémoire. Une recherche systématique des hyperparamètres a été conduite afin d'identifier la configuration optimale pour ce dataset, évaluée par LORO partiel sur trois sujets de référence (Subj04, Subj05, Subj07), voir Chapitre 5, section 5.1.3. Les paramètres retenus à l'issue de cette optimisation sont présentés dans le tableau suivant

Tableau III-3 : Hyperparamètres du modèle DeepConvNet.

Paramètre	Valeur
Nombre de blocs convolutifs	3
Filtres par bloc	$25 \rightarrow 50 \rightarrow 100$
Kernel temporel	1×64 (padding = 32)
Convolution spatiale	16×1 (premier bloc)
Type de pooling	MaxPooling (1×2)
Fonction d'activation	ELU
Optimiseur	Adam
Taux d'apprentissage	1×10^{-3}
Dropout	0,5
Taille de batch	64
Nombre maximal d'époques	15
Facteur d'augmentation	$\times 3$

Bande de fréquence	Mu (8–12 Hz) + Bêta (13–30 Hz)
Stratégie de validation	LORO (Leave-One-Run-Out)

ANNEXE IV

Résultats complémentaires de classification (Kaptics)

Cette annexe présente les résultats détaillés de classification obtenus sur le système Kaptics (électrodes sèches), en complément des résultats présentés au Chapitre 5, section 5.2. Les matrices de confusion individuelles sont fournies pour chaque sujet et chaque run testé lors de la validation Leave-One-Run-Out.

Figure IV-1 : Matrices de confusion RLDA, Sujet 02 (10 runs).




Figure IV-2 : Matrices de confusion RLDA, Sujet 03 (10 runs).




Figure IV-3 : Matrices de confusion RLDA, Sujet 04 (10 runs).





Figure IV-4 : Matrices de confusion RLDA, Sujet 05 (10 runs).



APPENDICE A

SCRIPTS DÉVELOPPÉS ET DÉTAILS D'IMPLEMENTATION

L'ensemble des scripts Python développés dans le cadre de ce projet est disponible publiquement sur GitHub :

https://github.com/emmacrll/DEEP_LEARNING_EEG.git

Ce dépôt inclut :

- Le pipeline de prétraitement des signaux EEG (Kaptics et humide)
- Le script de monitoring temps réel du signal Kaptics (STD, PSD, ERD)
- Le script d'analyse de la qualité des données et de sélection des sujets
- Le pipeline de classification RLDA
- Les architectures EEGNet et DeepConvNet
- Le script de recherche d'hyperparamètres

LISTE DE RÉFÉRENCES BIBLIOGRAPHIQUES

- Alchalabi, B., Shirmohammadi, S., Eddin, A. N., & Elsharnouby, M. (2021a). EPHY: A multimodal BCI-based system for motor rehabilitation of patients with motor disabilities. *IEEE Transactions on Instrumentation and Measurement*, 70, 1-15.
- Alchalabi, B., Shirmohammadi, S., Eddin, A. N., & Elsharnouby, M. (2021b). A modified RLDA-based BCI for motor rehabilitation using EEG signals. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 27(10), 2163-2172.
- Ang, K. K., Chua, K. S. G., Phua, K. S., Wang, C., Chin, Z. Y., Kuah, C. W. K., Low, W., & Guan, C. (2014). A randomized controlled trial of EEG-based motor imagery brain-computer interface robotic rehabilitation for stroke. *Clinical EEG and Neuroscience*, 46(4), 310-320.
- Blankertz, B., Tomioka, R., Lemm, S., Kawanabe, M., & Müller, K. R. (2008). Optimizing spatial filters for robust EEG single-trial analysis. *IEEE Signal Processing Magazine*, 25(1), 41-56.
- Boord, P., Craig, A., Tran, Y., & Nguyen, H. (2010). Discrimination of left and right leg motor imagery for brain-computer interfaces. *Medical & Biological Engineering & Computing*, 48(4), 343-350.
- Brumberg, J. S., Nguyen, A., Lorenz, D. J., & Guenther, F. H. (2016). Functional states of a speech BCI for motor impaired users. *Brain-Computer Interfaces*, 3(4), 191-205.
- Cervera, M. A., Soekadar, S. R., Ushiba, J., Millán, J. D. R., Liu, M., Birbaumer, N., & Garipelli, G. (2018). Brain-computer interfaces for post-stroke motor rehabilitation: A meta-analysis. *Annals of Clinical and Translational Neurology*, 5(6), 651-663.
- Daly, J. J., & Wolpaw, J. R. (2008). Brain-computer interfaces in neurological rehabilitation. *The Lancet Neurology*, 7(11), 1032-1043.
- Decety, J. (1996). The neurophysiological basis of motor imagery. *Behavioural Brain Research*, 77(1-2), 45-52.
- Hinrichs, H., Scholz, M., Baum, A. K., Kam, J. W. Y., Knight, R. T., & Heinze, H. J. (2020). Comparison between a wireless dry electrode EEG system with a conventional wired wet electrode EEG system for clinical applications. *Scientific Reports*, 10(1), 1-13.
- Jeannerod, M. (2001). Neural simulation of action: A unifying mechanism for motor cognition. *NeuroImage*, 14(1), S103-S109.
- Jeong, J.-H., Choi, J.-H., Kim, K.-T., Lee, S.-J., Kim, D.-J., & Kim, H.-M. (2021). Multi-domain convolutional neural networks for lower-limb motor imagery using dry vs. wet electrodes. *Sensors*, 21(19), 6672.

- Lawhern, V. J., Solon, A. J., Waytowich, N. R., Gordon, S. M., Hung, C. P., & Lance, B. J. (2018). EEGNet: A compact convolutional neural network for EEG-based brain-computer interfaces. *Journal of Neural Engineering*, 15(5), 056013.
- Lotte, F., Congedo, M., Lécuyer, A., Lamarche, F., & Arnaldi, B. (2007). A review of classification algorithms for EEG-based brain-computer interfaces. *Journal of Neural Engineering*, 4(2), R1-R13.
- Malouin, F., Richards, C. L., Jackson, P. L., Dumas, F., & Doyon, J. (2003). Brain activations during motor imagery of locomotor-related tasks: A PET study. *Human Brain Mapping*, 19(1), 47-62.
- Malouin, F., & Richards, C. L. (2010). Mental practice for relearning locomotor skills. *Physical Therapy*, 90(2), 240-251.
- Newson, J. J., & Thiagarajan, T. C. (2019). EEG frequency bands in psychiatric disorders: A review of resting state studies. *Frontiers in Human Neuroscience*, 12, 521.
- Pfurtscheller, G., & Neuper, C. (2001). Motor imagery and direct brain-computer communication. *Proceedings of the IEEE*, 89(7), 1123-1134.
- Roy, Y., Banville, H., Albuquerque, I., Gramfort, A., Falk, T. H., & Faubert, J. (2019). Deep learning-based electroencephalography analysis: A systematic review. *Journal of Neural Engineering*, 16(5), 051001.
- Schirrmester, R. T., Springenberg, J. T., Fiederer, L. D. J., Glasstetter, M., Eggensperger, K., Tangermann, M., Hutter, F., Burgard, W., & Ball, T. (2017). Deep learning with convolutional neural networks for EEG decoding and visualization. *Human Brain Mapping*, 38(11), 5391-5420.
- Soekadar, S. R., Witkowski, M., Gómez, C., Opisso, E., Medina, J., Cortese, M., Cempini, M., Carrozza, M. C., Cohen, L. G., Birbaumer, N., & Vitiello, N. (2016). Hybrid EEG/EOG-based brain/neural hand exoskeleton restores fully independent daily living activities after quadriplegia. *Science Robotics*, 1(1), eaag3296.
- Tariq, M., Trivailo, P. M., & Simic, M. (2018). EEG-based BCI control schemes for lower-limb assistive-robots. *Frontiers in Human Neuroscience*, 12, 312.
- Vourvopoulos, A., Pardo, O. M., Lefebvre, S., Neureither, M., Saldana, D., Jahng, E., & Liew, S. L. (2019). Effects of a brain-computer interface with virtual reality (VR) neurofeedback: A pilot randomized clinical trial in chronic stroke. *Frontiers in Human Neuroscience*, 13, 210.
- Wolpaw, J. R., Birbaumer, N., McFarland, D. J., Pfurtscheller, G., & Vaughan, T. M. (2002). Brain-computer interfaces for communication and control. *Clinical Neurophysiology*, 113(6), 767-791.